

Modelos interpretables para inversión financiera

Generación de señales de inversión mediante aprendizaje supervisado interpretable y detección de regímenes económicos: aplicación al S&P 500

UOC

Universitat Oberta
de Catalunya

Víctor Olivera Begué

Máster Ciencia de Datos
Forecasting in industrial
and business
environments

Tutor/a de TF

David García Agudíez

**Profesor/a responsable de
la asignatura**

Susana Acedo

06/2026



Esta obra está sujeta a una licencia
de [Reconocimiento-NoComercial-
SinObraDerivada 3.0 España de
Creative Commons](#)

Ficha del Trabajo Final

Título del trabajo:	Modelos interpretables para inversión financiera
Nombre del autor/a:	Víctor Olivera Begué
Nombre del Tutor/a de TF:	David García Agudéz
Nombre del/de la PRA:	Susana Acedo
Fecha de entrega:	06/2026
Titulación o programa:	Máster de ciencia de datos
Área del Trabajo Final:	Finanzas
Idioma del trabajo:	Castellano
Palabras clave	machine learning interpretable, Triple Barrier, Explainable Boosting Machine, modelos de Markov ocultos, destilación de modelos, trading algorítmico, validación walk-forward, detección de régimen



Resumen

Este trabajo desarrolla un sistema de generación de señales de inversión sobre el índice S&P 500 mediante técnicas de aprendizaje automático, con datos diarios comprendidos entre 2004 y 2024. El objetivo principal es estudiar si es posible construir modelos predictivos que sean al mismo tiempo precisos, estables e interpretables, tres propiedades que en la práctica suelen estar en tensión. Para definir el problema de clasificación se emplea el método de la Barrera Triple, que etiqueta cada día de trading en función de si el precio alcanza un nivel de beneficio, un nivel de pérdida máxima o agota el horizonte temporal antes de que ocurra cualquiera de los dos anteriores, lo que produce un objetivo más coherente con la gestión activa de posiciones que la simple predicción de dirección del precio. Sobre estas etiquetas se entrenan tres familias de modelos supervisados bajo un esquema de validación walk-forward con ventana expandible: un Explainable Boosting Machine como modelo principal, LightGBM como referencia de alta capacidad y un modelo destilado a partir de este último. Los tres modelos se comparan en términos de F1, AUC y estabilidad de la importancia de variables entre pliegues. En una segunda fase se incorpora un Modelo de Markov Oculto para identificar el régimen de mercado vigente y filtrar las señales supervisadas, activándolas únicamente cuando el mercado se encuentra en estado alcista. Los resultados del backtest fuera de muestra entre 2020 y 2024 muestran que los modelos obtienen métricas de riesgo ajustado superiores a las del benchmark Buy and Hold, aunque todas las curvas de equity quedan por debajo en retorno acumulado, lo que refleja el coste de permanecer en efectivo durante los periodos más alcistas del índice. El trabajo concluye con un análisis de interpretabilidad que compara las variables identificadas por cada modelo y extrae las condiciones de mercado que activan las señales, evaluando su coherencia económica.

Índice

RESUMEN.....	4
1. INTRODUCCIÓN.....	1
1.1 CONTEXTO Y JUSTIFICACIÓN DEL TRABAJO	1
1.2 OBJETIVOS DEL TRABAJO	2
1.3 IMPACTO EN SOSTENIBILIDAD, ÉTICO-SOCIAL Y DIVERSIDAD	2
1.4 ENFOQUE Y MÉTODO SEGUIDO	3
1.5 PLANIFICACIÓN DEL TRABAJO	3
2. ESTADO DEL ARTE.....	4
2.1 FUNDAMENTOS DEL ANÁLISIS FINANCIERO Y GENERACIÓN DE ALPHA	4
2.2 EVOLUCIÓN HACIA EL MACHINE LEARNING EN FINANZAS	4
2.3 PROBLEMAS EN EL ETIQUETADO DE DATOS FINANCIEROS	5
2.4 NO ESTACIONARIEDAD Y RÉGIMENES DE MERCADO	5
2.5 MODELOS DE MACHINE LEARNING PARA PREDICCIÓN FINANCIERA	6
2.6 INTERPRETABILIDAD EN MODELOS DE MACHINE LEARNING	6
2.7 DESTILACIÓN DE MODELOS Y MODELOS SUSTITUTOS	6
2.8 SÍNTESIS DEL ESTADO DEL ARTE	7
3. DISEÑO E IMPLEMENTACIÓN DEL TRABAJO.....	8
3.1 EXTRACCIÓN DE DATOS	8
3.2 INGENIERÍA DE VARIABLES	9
3.2.1 <i>Construcción de variables predictivas.....</i>	<i>9</i>
3.2.2 <i>Definición del objetivo de clasificación: método de la Barrera Triple</i>	<i>10</i>
3.2.3 <i>Selección y limpieza de variables</i>	<i>11</i>
3.2.4 PARTICIÓN TEMPORAL Y CONTROL DEL SESGO DE EVALUACIÓN	12
3.3 BÚSQUEDA DE HIPERPARÁMETROS Y ENTRENAMIENTO DEL MODELO	13
3.3.1 <i>Esquema de validación walk-forward con ventana expandible</i>	<i>13</i>
3.3.2 <i>Optimización de hiperparámetros con Optuna.....</i>	<i>13</i>
3.3.3 <i>Corrección del desequilibrio de clases.....</i>	<i>13</i>
3.3.4 <i>Modelos entrenados en la Iteración 1</i>	<i>14</i>
3.3.5 <i>Modelos entrenados en la Iteración 2</i>	<i>14</i>
3.4 VALIDACIÓN DEL RENDIMIENTO	15
3.4.1 <i>Métricas de clasificación.....</i>	<i>15</i>
3.4.2 <i>Ajuste del umbral de clasificación</i>	<i>16</i>
3.4.3 <i>Estabilidad temporal de la importancia de variables.....</i>	<i>16</i>

3.4.4	Validación del HMM en la Iteración 2	16
3.5	INTERPRETACIÓN DEL MODELO	17
3.5.1	Enfoque general de interpretabilidad	17
3.5.2	Shape functions del EBM	17
3.5.3	Análisis de importancia SHAP sobre LightGBM	17
3.5.4	Destilación y extracción de reglas del modelo student	18
3.5.5	Convergencia metodológica entre modelos	18
3.6	GENERACIÓN DE PREDICCIONES FUERA DE MUESTRA	18
3.7	BACKTESTING CON SEÑALES DIARIAS	19
3.7.1	Diseño de la estrategia de evaluación	19
3.7.2	Modelización de costes de transacción	19
3.7.3	Métricas de evaluación financiera	20
3.8	ITERACIÓN 1 — CLASIFICACIÓN SUPERVISADA CON MODELOS INTERPRETABLES	20
3.8.1	Punto de partida y objetivos de la iteración	20
3.8.2	Decisiones metodológicas y aprendizajes durante el desarrollo	20
3.8.3	Selección de variables por pliegue	21
3.8.4	Aprendizajes metodológicos de la Iteración 1	21
3.9	ITERACIÓN 2 — DETECCIÓN DE RÉGIMEN Y SEÑAL CONDICIONADA	22
3.9.1	Motivación y objetivos de la iteración	22
3.9.2	Decisiones metodológicas y aprendizajes durante el desarrollo	22
3.9.3	Exploración de una capa adicional de confirmación de tendencia	23
3.9.4	Aprendizajes metodológicos de la Iteración 2	23
4.	RESULTADOS	24
4.1	RESULTADOS DE LA ITERACIÓN 1	24
4.1.1	Rendimiento en validación walk-forward	24
4.1.2	Selección de variables y estabilidad SHAP	25
4.1.3	Análisis del modelo student	27
4.1.4	Resultados del backtest fuera de muestra	28
4.2	RESULTADOS DE LA ITERACIÓN 2	31
4.2.1	Validación del modelo HMM: caracterización de regímenes	31
4.2.2	Efecto del filtro HMM en la validación walk-forward	33
4.2.3	Resultados del backtest fuera de muestra	33
4.3	ANÁLISIS DE EXPLICABILIDAD E INTERPRETABILIDAD	36
4.3.1	Convergencia metodológica entre EBM y LightGBM	36
4.3.2	Shape functions del EBM	36
4.3.3	Reglas del modelo student	37

5. CONCLUSIONES.....	39
5.1 SOBRE EL ETIQUETADO CON BARRERA TRIPLE	39
5.2 SOBRE LOS MODELOS INTERPRETABLES Y EL COSTE DE LA CAJA NEGRA	39
5.2.1 <i>Logros.....</i>	39
5.2.2 <i>Autocrítica.....</i>	40
5.3 SOBRE EL VALOR AÑADIDO DE LA DETECCIÓN DE RÉGIMEN	40
5.3.1 <i>Logros.....</i>	40
5.3.2 <i>Autocrítica y propuesta de mejora.....</i>	41
5.4 SOBRE LAS SEÑALES FINANCIERAS Y SU UTILIDAD PRÁCTICA	41
5.4.1 <i>Logros.....</i>	41
5.4.2 <i>Reflexión sobre las equity curves.....</i>	41
5.5 LIMITACIONES DEL TRABAJO	42
5.6 LÍNEAS DE TRABAJO FUTURO	42
5.7 VERIFICACIÓN DE HIPÓTESIS	43
REFERENCIAS.....	44

Lista de figuras

Figura 1. Diagrama de Gantt.....	3
Figura 2. Diagnóstico Triple Barrier $k=0.7$, $\text{span}=20$, $\text{max_holding}=7d$	11
Figura 3. Top-16 features por Cohen's d - train-val	12
Figura 4. Regímenes HMM - Fold 6 (train 2004-2019)	15
Figura 5. Bid-ask spreads for the typical S&P 500 stock have widened sharply over the past week	19
Figura 6. Comparativa de modelos - métricas de validación por fold	25
Figura 7. Estabilidad SHAP entre folds – EBM.....	26
Figura 8. Estabilidad SHAP entre folds – LGBM	27
Figura 9. Comparativa destilación - RuleFit vs Árbol de Decisión	28
Figura 10. Equity Curves OOS (2020-2024) - threshold=0.3.....	30
Figura 11. Diagnóstico OOS - Performance anual desagregada.....	30
Figura 12. Régimen HMM en OOS (2020-2024)	32
Figura 13. Distribución por estado HMM - Fold 6	32
Figura 14. Equity Curves OOS 2020-2024.....	35
Figura 15. Sharpe anual OOS - Iter1 vs Iter2 vs Breakout	35
Figura 16. EBM - Shape functions (Fold 6, train hasta 2018-12-31).....	36
Figura 22. EBM - Importancia global y dirección del efecto (fold 6).....	37
Figura 23. EBM - Efectos de la interacción top-6 (fold 3)	¡Error! Marcador no definido.
Figura 24. Comparativa validación walk-forward: iter1 vs iter2 / EBM - LightGBM - Student (DT/RuleFit)	¡Error! Marcador no definido.
Figura 25. Análisis de actividad de señales por versión	¡Error! Marcador no definido.

Lista de tablas

Tabla 1. Variables extraídas por fuente de datos	8
Tabla 2. Variables predictivas construidas por categoría	10
Tabla 3. Distribución de la muestra y balance de clases por periodo	12
Tabla 4. Diseño del esquema walk-forward	13
Tabla 5. Comparativa de los tres modelos de la Iteración 1	14
Tabla 6. Resumen de métricas de validación walk-forward — Iteración 1	24
Tabla 7. Métricas de validación por pliegue — Iteración 1	24
Tabla 8. Variables seleccionadas por pliegue (EBM y LightGBM)	25
Tabla 9. Importancia SHAP media — Top 10 variables	26
Tabla 10. Comparativa RuleFit vs Árbol de Decisión por pliegue	27
Tabla 11. Métricas financieras del backtest OOS 2020-2024 — Iteración 1	28
Tabla 12. Sharpe anual por modelo — OOS 2020-2024	29
Tabla 13. Estadísticas de emisión por estado HMM — Pliegue 6 (entrenamiento 2004-2019)	31
Tabla 14. Estabilidad de los regímenes HMM entre pliegues	31
Tabla 15. Comparativa de métricas de validación walk-forward — Iter1 vs Iter2	33
Tabla 16. Métricas financieras OOS — comparativa Iter1, Iter2 y Breakout	33
Tabla 17. Sharpe anual por modelo y versión — OOS 2020-2024	34
Tabla 18. Condiciones de mercado recurrentes en las hojas alcistas del árbol destilado	38

1. Introducción

Los mercados financieros han cambiado mucho en las últimas décadas. La globalización, la digitalización y el volumen creciente de datos disponibles han hecho que operar en ellos sea bastante más complicado que antes. Los modelos estadísticos tradicionales y el análisis humano directo funcionaban bien en entornos más estables, pero tienen dificultades cuando los datos presentan comportamientos no lineales o cuando las condiciones del mercado cambian de forma brusca.

Frente a esto, el Machine Learning ha ganado protagonismo en el análisis cuantitativo y el trading algorítmico. Permite trabajar con grandes volúmenes de datos, detectar relaciones entre variables que los modelos clásicos no captarían y ajustarse a entornos cambiantes. Aun así, su uso en finanzas reales no está exento de problemas: muchos modelos son difíciles de interpretar, su rendimiento suele ser inestable a lo largo del tiempo y evaluarlos en mercados con poca memoria estadística es complicado.

Este Trabajo Final de Máster analiza el uso de técnicas de Machine Learning para generar y evaluar señales de inversión en el S&P 500 con datos diarios. El trabajo sigue metodologías reconocidas en la literatura, como las descritas en *Machine Learning for Algorithmic Trading*, y busca estudiar de forma sistemática el equilibrio entre capacidad predictiva, interpretabilidad y estabilidad temporal de los modelos.

1.1 Contexto y justificación del trabajo

El problema central que motiva este trabajo es construir modelos predictivos que sean, al mismo tiempo, precisos, estables e interpretables. En la práctica, la mayoría de los trabajos en este campo se centran en maximizar métricas de rendimiento y dejan en un segundo plano la transparencia del modelo o su comportamiento ante distintos escenarios de mercado.

Un punto conflictivo es cómo definir el objetivo de predicción. Usar como etiqueta simplemente la dirección del precio es poco realista desde un punto de vista financiero: no incorpora criterios de riesgo ni horizontes temporales con sentido práctico. A esto se suma que los mercados presentan cambios de régimen frecuentes, lo que hace que patrones aprendidos en un periodo concreto dejen de funcionar más adelante.

Hasta ahora, estas dos problemáticas se han tratado por separado. Los modelos complejos, como los basados en ensembles o boosting, ofrecen buena capacidad predictiva pero son difíciles de interpretar. Los modelos más interpretables, por su parte, suelen rendir menos o no se evalúan con rigor fuera de muestra.

Este trabajo propone un marco que aborde los dos problemas a la vez. Para ello se utiliza el método de etiquetado de barrera triple, que define el objetivo de clasificación con criterios de rentabilidad y control de riesgo; se comparan modelos complejos con modelos interpretables; y se incorpora la detección de regímenes de mercado para analizar su

efecto sobre el rendimiento y la estabilidad de los modelos. El objetivo es obtener conclusiones concretas y aplicables sobre el uso de Machine Learning en entornos financieros reales.

1.2 Objetivos del trabajo

El objetivo general es evaluar la aplicabilidad y el rendimiento de distintos modelos de Machine Learning para generar señales de inversión en el S&P 500, prestando atención a la interpretabilidad y al comportamiento en mercados no estacionarios.

Los objetivos específicos son:

- Implementar un esquema de etiquetado basado en el método de la barrera triple para definir el problema de clasificación.
- Desarrollar y evaluar modelos de distinta complejidad, incluyendo ensembles y modelos interpretables como Explainable Boosting Models.
- Aplicar técnicas de destilación de modelos para extraer reglas interpretables a partir de los modelos más complejos.
- Identificar regímenes de mercado mediante técnicas no supervisadas y analizar su efecto sobre el rendimiento y la estabilidad de los modelos.
- Explorar, si la planificación lo permite, el uso de los modelos como filtros de señal en estrategias de tipo breakout.

1.3 Impacto en sostenibilidad, ético-social y diversidad

El trabajo no tiene impacto medioambiental directo, ya que se basa en datos financieros históricos y modelos computacionales. En todo caso, unos modelos de inversión más eficientes y robustos contribuyen indirectamente a una asignación de capital más racional, lo que tiene cierto encaje con principios de finanzas sostenibles.

En el plano ético, el trabajo aborda de forma directa el problema de la opacidad en los modelos de Machine Learning. Cuando un modelo influye en la gestión de activos o en la evaluación del riesgo sin que sea posible entender cómo llega a sus conclusiones, el riesgo no es solo técnico, sino también institucional. Al centrarse en modelos interpretables y en la destilación de modelos complejos, el trabajo apunta hacia prácticas más transparentes y auditables.

Respecto a la diversidad, el enfoque adoptado facilita que profesionales sin un perfil altamente técnico puedan entender y cuestionar las decisiones que toman estos modelos. Esto reduce la dependencia de los llamados modelos de caja negra y contribuye a que el análisis cuantitativo sea accesible a un rango más amplio de personas.

1.4 Enfoque y método seguido

Para gestionar proyectos de Machine Learning en entornos profesionales se utilizan principalmente dos marcos de referencia: CRISP-DM y las metodologías Agile. CRISP-DM organiza el trabajo en fases secuenciales, desde la comprensión del problema hasta la evaluación de resultados. Las metodologías Agile, por su parte, estructuran el trabajo en iteraciones cortas con revisiones continuas.

Este trabajo sigue principalmente CRISP-DM, porque encaja bien con las fases del proyecto: comprensión del problema financiero, preparación de datos, modelado, evaluación y análisis de resultados. Se complementa con un enfoque iterativo de tipo Agile, en el que los modelos y las hipótesis se ajustan progresivamente según los resultados obtenidos en cada fase.

La combinación de ambos marcos permite mantener una estructura clara sin perder la flexibilidad necesaria para adaptarse a lo que vaya surgiendo durante el desarrollo.

1.5 Planificación del trabajo

El trabajo se organiza en cinco módulos consecutivos, siguiendo el calendario oficial de la asignatura, con inicio el 3 de marzo de 2026 y defensa pública el 26 de junio de 2026.

El primer módulo, hasta principios de marzo, cubre la definición del problema, los objetivos y el enfoque metodológico. El segundo, hasta el 22 de marzo, desarrolla el estado del arte para justificar la línea de investigación y precisar las técnicas a utilizar.

Entre finales de marzo y principios de junio se lleva a cabo la fase central: preparación de datos, modelización y evaluación financiera, incluyendo el análisis sobre el S&P 500 y la incorporación de la detección de regímenes de mercado.

En mayo comienza la redacción formal de la memoria, con versión preliminar el 17 de mayo y versión final el 24 de mayo. Después se prepara la presentación y la documentación para el tribunal.

Esta distribución concentra la mayor parte del tiempo en el desarrollo experimental, que es el núcleo del proyecto. En el anexo se incluye un diagrama de Gantt con todas las tareas y sus fechas.




Figura 1. Diagrama de Gantt

2. Estado del arte

2.1 Fundamentos del análisis financiero y generación de alpha

El análisis financiero parte de una idea básica: a mayor riesgo asumido, mayor rentabilidad esperada. El modelo más influyente para formalizar esta relación es el Capital Asset Pricing Model (CAPM), que establece que la rentabilidad esperada de un activo depende de su exposición al riesgo sistemático del mercado, medida a través del coeficiente beta (Sharpe, 1964).

El CAPM tiene una limitación importante: asume que el mercado es la única fuente de riesgo relevante. Jensen (1968) introduce el concepto de alpha para medir la rentabilidad que una cartera obtiene por encima de lo que el modelo predice. En la gestión activa, el alpha es el indicador clave para saber si una estrategia añade valor real o simplemente replica el comportamiento del mercado.

Más adelante, los modelos multifactoriales amplían este marco. Fama y French (1993) proponen incorporar factores como el tamaño de las empresas y su valoración relativa, lo que mejora la capacidad explicativa de los retornos. De aquí surge el factor investing, donde identificar factores con poder predictivo se convierte en el eje de la generación de alpha.

2.2 Evolución hacia el Machine Learning en finanzas

El aumento de datos disponibles y la mayor capacidad de cómputo han abierto la puerta a métodos más avanzados en el análisis financiero. El Machine Learning se incorpora como una herramienta para mejorar la calidad de las predicciones y, con ello, la generación de alpha.

Jansen (2020) describe cómo el uso de algoritmos en finanzas ha pasado de automatizar la ejecución de órdenes a optimizar el proceso completo de inversión: generación de ideas, extracción de señales, asignación de activos y gestión del riesgo.

En este punto es útil la ley fundamental de la gestión activa de Grinold (1989), que establece que el rendimiento de una estrategia depende de la precisión de sus predicciones y del número de decisiones independientes que se pueden tomar. El Machine Learning mejora los dos aspectos: permite procesar más datos y detectar relaciones que los modelos clásicos no captarían.

A esto se añade que la rentabilidad de los factores tradicionales se ha ido reduciendo con el tiempo, un fenómeno conocido como factor decay. Esto ha empujado a desarrollar modelos más complejos que se adapten mejor a entornos cambiantes.

2.3 Problemas en el etiquetado de datos financieros

Uno de los problemas menos discutidos en la aplicación de Machine Learning a finanzas es cómo definir correctamente la variable que los modelos intentan predecir. Los primeros trabajos en este campo usaban métodos simples: la etiqueta era si el precio subía o bajaba en un horizonte de tiempo fijo.

Este enfoque tiene problemas obvios. No tiene en cuenta la gestión del riesgo ni cómo funcionan realmente las estrategias de trading, donde las posiciones se cierran por niveles de beneficio o pérdida, no solo por el paso del tiempo.

Para corregir esto, López de Prado (2018) propone el método de Triple Barrier Labeling en su obra *Advances in Financial Machine Learning*. La idea es etiquetar cada observación según cuál de tres eventos ocurre primero: que el precio alcance un nivel de beneficio objetivo, que alcance un nivel de pérdida máxima, o que expire el horizonte temporal sin haber tocado ninguno de los dos. El resultado son etiquetas más coherentes con la lógica real de una operación de trading.

Singh y Joubert (2019) muestran que combinar este tipo de etiquetado con técnicas de muestreo basadas en eventos y meta-labeling mejora el rendimiento de estrategias de trading automático y reduce el sobreajuste. Fu et al. (2024) van más lejos y proponen una versión del método optimizada mediante algoritmos genéticos aplicada a mercados de criptomonedas, con mejoras tanto en rentabilidad como en control del riesgo.

En general, estos trabajos confirman que la calidad del etiquetado tiene un impacto directo en el rendimiento final de los modelos, y que vale la pena dedicar atención a esta fase antes de entrar en el modelado.

2.4 No estacionariedad y regímenes de mercado

Los mercados financieros no se comportan igual en todo momento. Alternan fases alcistas, bajistas y periodos de alta volatilidad, y los modelos entrenados en un tipo de entorno a menudo fallan cuando las condiciones cambian. Esto es lo que se conoce como no estacionariedad.

Una forma de abordarlo es identificar en qué régimen se encuentra el mercado en cada momento y adaptar el modelo en consecuencia. Los Hidden Markov Models (HMM) son una de las herramientas más usadas para esto: permiten inferir estados ocultos en una serie temporal a partir de las observaciones disponibles, sin necesidad de definirlos a priori.

Nguyen (2018) aplica un HMM de cuatro estados al S&P 500 y muestra que supera a métodos basados en promedios históricos tanto en predicción como en estrategias de trading. Wang, Lin y Mikhelson (2020) usan modelos similares para adaptar dinámicamente estrategias basadas en factores según el régimen detectado, con resultados superiores a los de modelos estáticos. Oelschläger y Adam (2020) exploran versiones jerárquicas de los HMM capaces de capturar tendencias a distintos horizontes temporales, lo que permite construir una representación más completa del mercado.

En conjunto, la detección de regímenes de mercado aparece como un elemento relevante para mejorar la robustez de los modelos predictivos.

2.5 Modelos de Machine Learning para predicción financiera

Una vez definidas las etiquetas y preparados los datos, la elección del modelo es el siguiente paso. La literatura muestra que los métodos de ensemble basados en árboles de decisión, como Random Forest y los modelos de Gradient Boosting, son los que mejor funcionan en este tipo de problemas. Permiten capturar relaciones no lineales y trabajar con muchas variables predictivas sin demasiado ajuste manual.

LightGBM, desarrollado por Microsoft, es uno de los más utilizados en la práctica por su eficiencia computacional y sus buenos resultados en conjuntos de datos grandes. Implementa un sistema de boosting sobre árboles de decisión que permite entrenar modelos precisos en tiempos razonables, lo que lo convierte en una opción natural para proyectos con series temporales financieras.

2.6 Interpretabilidad en modelos de Machine Learning

En finanzas, no basta con que un modelo prediga bien. También es necesario entender por qué toma las decisiones que toma, tanto para gestionar el riesgo como para cumplir con criterios de auditoría y transparencia.

La literatura reciente ha desarrollado varias técnicas para interpretar modelos complejos. Molnar (2022) recoge un amplio catálogo de estas herramientas, entre las que destacan SHAP y LIME. Ambas permiten estimar el impacto de cada variable en las predicciones de modelos como LightGBM sin necesidad de modificar su estructura interna. En este trabajo, estas técnicas se usarán para analizar el comportamiento del modelo predictivo principal.

Una alternativa más directa son las Explainable Boosting Machines (EBM), que pertenecen a la familia de los Generalized Additive Models pero incorporan técnicas de boosting para mejorar su capacidad predictiva. Nori et al. (2021) muestran que los EBM pueden alcanzar niveles de precisión comparables a los de modelos más complejos manteniendo una interpretabilidad completa, tanto a nivel global como para predicciones individuales. Esto los convierte en una opción interesante cuando la comprensión del modelo es tan importante como su rendimiento.

2.7 Destilación de modelos y modelos sustitutos

Otra forma de mejorar la interpretabilidad de un modelo complejo es entrenar un modelo más simple que aprenda a imitarlo. A esto se le llama destilación de modelos o surrogate models.

Hinton, Vinyals y Dean (2015) formalizan este concepto y demuestran que es posible transferir gran parte del conocimiento de un modelo complejo a uno más sencillo sin perder

demasiada precisión. En la práctica, esto permite analizar el comportamiento del modelo original de forma más accesible.

Una de las técnicas más relevantes en este ámbito es RuleFit (Friedman y Popescu, 2008), que transforma un modelo de árboles en un conjunto de reglas interpretables combinadas en un modelo lineal disperso. Chevalier, Coqueret y Raffinot (2022) aplican esta técnica a modelos de gradient boosting en distintos universos de inversión y muestran que permite aproximar el modelo original con poca pérdida de precisión, al tiempo que las reglas extraídas ayudan a identificar qué variables y combinaciones de variables son relevantes para construir carteras. En este trabajo, RuleFit se usará para simplificar el modelo LightGBM y transformar sus predicciones en condiciones económicas explícitas.

En una línea similar, SkopeRules genera reglas directamente a partir de modelos de árboles priorizando las que tienen mayor precisión y cobertura. Lal, Chen y Mithal (2024) proponen TE2Rules, un método alternativo que extrae reglas de modelos de gradient boosting con alta fidelidad y un número reducido de reglas, con especial rendimiento en clases minoritarias. Ambos enfoques permiten traducir el comportamiento de modelos complejos en patrones de decisión comprensibles, lo que en finanzas se traduce en condiciones de mercado concretas asociadas a señales de inversión.

Estas técnicas van más allá de la interpretabilidad post-hoc: no solo explican el modelo, sino que convierten sus predicciones en reglas que pueden integrarse directamente en un proceso de toma de decisiones.

2.8 Síntesis del estado del arte

La aplicación de Machine Learning en los mercados financieros ha avanzado considerablemente en la última década, impulsada por la mayor disponibilidad de datos y el aumento de la capacidad computacional.

Varios trabajos han señalado la importancia de cuidar cada fase del proceso de modelado. El etiquetado mediante Triple Barrier Labeling genera datos más coherentes con la lógica de las operaciones reales. La detección de regímenes de mercado con modelos como los HMM ayuda a lidiar con la no estacionariedad. Los modelos de gradient boosting, especialmente LightGBM, han demostrado buenos resultados capturando relaciones no lineales en series financieras. Y las técnicas de interpretabilidad, tanto los EBM como los métodos de destilación, permiten entender qué está aprendiendo el modelo.

Este trabajo se sitúa en la intersección de estas líneas de investigación. La propuesta combina etiquetado avanzado, detección de regímenes y modelos interpretables para analizar su aplicación conjunta en estrategias de inversión sobre datos históricos del S&P 500.

3. Diseño e implementación del trabajo

3.1 Extracción de datos

Con el objetivo de generar señales de inversión sobre el mercado de renta variable estadounidense, el activo analizado es el índice S&P 500, con datos diarios de precio de cierre ajustado desde enero de 2004 hasta diciembre de 2024. El periodo 2004–2019 se usa íntegramente para desarrollar el sistema, y el periodo 2020–2024 queda bloqueado hasta la evaluación final.

Las variables se extraen de cuatro fuentes. Las series macroeconómicas de FRED se publican con baja frecuencia y con retardo; para respetar la causalidad temporal, cada serie se remuestra a frecuencia diaria propagando hacia adelante el último valor publicado hasta que aparece uno nuevo.

Yahoo Finance	FRED	CBOE / Yahoo	ETFs sectoriales
S&P 500 (OHLCV)	Curva de tipos (yield_curve)	VIX	XLE — Energía
Petróleo WTI (oil)	Diferencial crédito IG (corp_oas)	VIX × WTI (vixoil)	XLF — Financiero
	Diferencial HY EE.UU. (hy_oas)		XLI — Industrial
	Diferencial HY Europa (eu_hy_oas)		XLK — Tecnología
	Sentimiento consumidor (sentiment)		XLV — Salud
	Empleo no agrícola (empleo)		XLY — Consumo discrecional
	PIB real (real_gdp)		
	Inflación (inflacion)		
	Indicador adelantado (leading)		
	Peticiones desempleo (weekjobclaims)		
	Ventas minoristas % (retail_sales_percent)		
	Ventas minoristas (retail_sales)		
	Balance activos Fed (us_asset_balance)		
	Tipo a 1 año (1y_yield)		
	Indicador recesión (recession)		

Tabla 1. Variables extraídas por fuente de datos

A partir de estas fuentes se construyen 40 variables predictivas iniciales: indicadores técnicos del índice, variables macroeconómicas y de crédito, indicadores de volatilidad y riesgo, y retornos de ETFs sectoriales. El VIX se trata como variable protegida: además de ser un predictor relevante, actúa como input del modelo HMM en la Iteración 2 y queda excluido del proceso de eliminación por colinealidad.

3.2 Ingeniería de variables

3.2.1 Construcción de variables predictivas

El punto de partida es que la dirección a corto plazo del mercado está influida por tres tipos de información: la dinámica técnica reciente del índice, el contexto macroeconómico y el comportamiento relativo de los sectores que lo componen. Todas las variables se construyen sin look-ahead bias: cada una representa información disponible al cierre del día anterior a la señal.

Categoría	Variable	Descripción	Nota
Tendencia	sma_10, sma_50	Medias móviles simples 10 y 50 días	
	ema_10	Media móvil exponencial 10 días	
	trend_strength	Fuerza de la tendencia	
	zscore_20	Posición del precio respecto a su media 20d normalizada	Mayor d de Cohen en EDA; top SHAP en todos los modelos
Momento	momentum_5, momentum_20	Retorno acumulado a 5 y 20 días	
	return_1d, return_5d, return_20d	Retornos a 1, 5 y 20 días	
Volatilidad y estrés	rsi	RSI 14 periodos (sobrecompra/sobreventa)	
	vol_ewm_20, volatility_20	Volatilidad EWM y realizada a 20 días	vol_ewm_20 usada como input del HMM
	atr_14	Average True Range 14 periodos	
	vol_regime	Régimen de volatilidad relativa a historia reciente	
	drawdown	Caída acumulada respecto al máximo del último año	Captura estrés estructural independiente del retorno diario
Macro crédito y	yield_curve	Pendiente de la curva de tipos	Predictor de ciclo bursátil (Ang y Timmermann, 2012)
	corp_oas, eu_hy_oas, hy_oas	Diferenciales crédito IG, HY EE.UU. y HY Europa	Apetito por el riesgo y condiciones de financiación
	vix, vixoil	VIX y producto VIX × WTI	Protegida; input del HMM en Iteración 2
	oil	Precio petróleo WTI	Ciclo global de materias primas
	recession	Indicador de recesión NBER	
	sentiment	Sentimiento del consumidor	
	empleo	Empleo no agrícola	
	real_gdp	PIB real	Frecuencia trimestral; forward-fill diario
	inflacion	Inflación	Frecuencia mensual; forward-fill diario
	leading	Indicador adelantado	
	weekjobclaims	Peticiones semanales de desempleo	

	retail_sales, retail_sales_percent	Ventas minoristas en nivel y variación	
	us_asset_balance	Balance de activos de la Fed	
	1y_yield	Tipo de interés a 1 año	
Sectorial	sector_XLE, XLF, XLI, XLK, XLV, XLY	Retornos diarios de 6 ETFs sectoriales	Capturan rotación sectorial como señal adelantada

Tabla 2. Variables predictivas construidas por categoría

3.2.2 Definición del objetivo de clasificación: método de la Barrera Triple

En lugar de predecir la dirección del precio a n días, que ignora el riesgo asumido y cómo funcionan las posiciones en la práctica, se adopta el método de la Barrera Triple (López de Prado, 2018). Una posición se cierra cuando ocurre lo primero de tres cosas: el precio alcanza el nivel de beneficio objetivo (take profit), alcanza el nivel de pérdida máxima (stop loss), o se agota el horizonte temporal máximo. Las barreras se escalan con la volatilidad histórica σ_t , calculada solo con datos anteriores al día t :

- Barrera superior (take profit): $P_t \times (1 + k \cdot \sigma_t \cdot \sqrt{h})$
- Barrera inferior (stop loss): $P_t \times (1 - k \cdot \sigma_t \cdot \sqrt{h})$

La etiqueta es binaria: 1 si el precio toca la barrera superior antes que la inferior o antes de agotar el horizonte, 0 en caso contrario. Al escalar con la volatilidad, las barreras se amplían cuando el mercado es más incierto y se estrechan cuando es más tranquilo.

Las barreras son simétricas, lo que garantiza que la etiqueta positiva representa una ventaja real solo cuando la probabilidad de subida supera genuinamente a la de bajada. Los parámetros $k=0.7$ y $h=7$ días hábiles se seleccionan empíricamente. Con esta configuración, la proporción de clase positiva es del 38.4% en entrenamiento, y la barrera temporal solo se activa en el 31.1% de los casos, lo que confirma que las etiquetas reflejan la dinámica del mercado y no simplemente el agotamiento del horizonte.




Figura 2. Diagnóstico Triple Barrier | $k=0.7$, $\text{span}=20$, $\text{max_holding}=7d$

3.2.3 Selección y limpieza de variables

Las variables construidas presentan redundancias inevitables: medias móviles de distintos plazos están muy correlacionadas entre sí, y varias series macroeconómicas miden aspectos solapados del ciclo económico. Variables redundantes perjudican tanto la interpretabilidad de los modelos como la estabilidad numérica de los métodos que requieren estimar estructuras de correlación.

La limpieza se realiza en dos etapas. Primero se identifican pares con correlación de Pearson absoluta superior a 0.95 y se descarta la variable de menor varianza del par, con el VIX excluido de este proceso. Después se calcula el Factor de Inflación de la Varianza para las variables restantes y se eliminan iterativamente las que superan un valor de diez, hasta que todas presentan un nivel de multicolinealidad aceptable.

El resultado es un conjunto de 28 variables con poca multicolinealidad. El análisis exploratorio muestra que ninguna variable individual presenta una separabilidad entre clases superior a $d=0.22$ según el coeficiente de Cohen, lo que indica que la capacidad predictiva del sistema reside en las combinaciones e interacciones entre variables, no en ninguna variable por sí sola.




Figura 3. Top-16 features por Cohen's d - train-val

3.2.4 Partición temporal y control del sesgo de evaluación

Para evitar el sobreajuste temporal se aplica una partición estricta e irreversible: el periodo 2004–2019 se destina al desarrollo del sistema y el periodo 2020–2024 permanece bloqueado hasta la evaluación final, donde se abre una única vez. Ninguna decisión metodológica, incluyendo el etiquetado, los parámetros de barrera o la limpieza de variables, se tomó con acceso a los datos del periodo fuera de muestra. La distribución de clases es prácticamente igual en ambos periodos, lo que confirma que el etiquetado no tiene sesgo temporal sistemático.

Periodo	Uso	Años	Clase positiva (%)	Clase negativa (%)
2004–2019	Entrenamiento y validación walk-forward	16	38.3%	61.7%
2020–2024	Evaluación fuera de muestra (OOS)	5	39.7%	60.3%

Tabla 3. Distribución de la muestra y balance de clases por periodo

3.3 Búsqueda de hiperparámetros y entrenamiento del modelo

3.3.1 Esquema de validación walk-forward con ventana expandible

La validación cruzada estándar rompe el orden temporal de las series financieras e introduce información futura en el entrenamiento. Para evitarlo se usa el esquema walk-forward con ventana expandible, habitual en la literatura de ML aplicado a trading (López de Prado, 2018; Jansen, 2020): el conjunto de entrenamiento crece en cada pliegue preservando el orden cronológico. La ventana expandible es preferible a la deslizante porque preserva ciclos históricos completos y episodios de alta volatilidad, lo que mejora la robustez del modelo. El diseño de los seis pliegues es idéntico en ambas iteraciones, de modo que cualquier diferencia entre ellas es atribuible exclusivamente a los cambios metodológicos introducidos.

Fold	Train desde	Train hasta	Validación	N train	N val
1	2004-01-02	2013-12-31	2014-01-01 → 2014-12-31	2.517	252
2	2004-01-02	2014-12-31	2015-01-01 → 2015-12-31	2.769	252
3	2004-01-02	2015-12-31	2016-01-01 → 2016-12-31	3.021	252
4	2004-01-02	2016-12-31	2017-01-02 → 2017-12-31	3.273	251
5	2004-01-02	2017-12-31	2018-01-01 → 2018-12-31	3.524	251
6	2004-01-02	2018-12-31	2019-01-01 → 2019-12-31	3.775	252

Tabla 4. Diseño del esquema walk-forward

3.3.2 Optimización de hiperparámetros con Optuna

La búsqueda de hiperparámetros se realiza con Optuna, usando el algoritmo TPE (Tree-structured Parzen Estimator), que construye un modelo probabilístico del espacio de búsqueda a partir de evaluaciones previas y dirige la exploración hacia las regiones más prometedoras (Bergstra y Bengio, 2012). La optimización se realiza de forma anidada dentro de cada pliegue del walk-forward, aplicando una partición interna sobre el conjunto de entrenamiento para identificar la combinación de hiperparámetros con mejor AUC-ROC. Este diseño garantiza que la búsqueda no contamina el conjunto de validación en ningún momento, por lo que las métricas reportadas son genuinamente fuera de muestra tanto para los hiperparámetros como para los parámetros del modelo.

3.3.3 Corrección del desequilibrio de clases

El dataset tiene aproximadamente un 38% de etiquetas positivas. Aunque no es un desequilibrio extremo, ignorarlo hace que los modelos tiendan a predecir siempre la clase mayoritaria, lo que produce una accuracy alta pero un F1 cercano a cero para la clase de interés.

La corrección varía según el modelo. Para el EBM se calcula un vector de pesos con `compute_sample_weight(balanced)`, que asigna a cada observación un peso inversamente proporcional a la frecuencia de su clase. Para LightGBM se usa el parámetro

scale_pos_weight, calculado como la ratio entre ejemplos negativos y positivos del pliegue correspondiente y recalculado en cada pliegue de forma dinámica.

3.3.4 Modelos entrenados en la Iteración 1

La Iteración 1 usa tres familias de modelos con distintos niveles de interpretabilidad.

El EBM es el modelo principal. Implementa un GAM en el que cada variable contribuye mediante una función unidimensional aprendida por gradient boosting de stumps, con interacciones de segundo orden controladas. Su interpretabilidad es exacta: la contribución de cada variable es legible directamente, sin aproximaciones. Se aplica calibración isotónica post-entrenamiento para reescalar las probabilidades al intervalo unitario.

LightGBM actúa como modelo de referencia de alta capacidad, estableciendo el límite superior de rendimiento predictivo. La diferencia respecto al EBM cuantifica el coste de optar por interpretabilidad.

El modelo student destila el conocimiento del LightGBM siguiendo el patrón surrogate global (Molnar, 2022): se entrena para imitar las probabilidades del LightGBM, no las etiquetas originales, lo que reduce el ruido del Triple-Barrier. Se prueban RuleFit (Friedman y Popescu, 2008) y árbol de decisión como alternativas; el student definitivo de cada pliegue se elige por AUC en validación, usando el árbol cuando RuleFit no converge en tiempo límite.

	EBM	LightGBM	Student
Rol	Modelo principal	Referencia de alta capacidad	Destilación interpretable
Interpretabilidad	Exacta (shape functions)	Post-hoc (SHAP)	Exacta (reglas IF-THEN / árbol)
Arquitectura	GAM + interacciones	Gradient boosting de árboles	RuleFit o árbol de decisión
Entrenado sobre	Etiquetas Triple-Barrier	Etiquetas Triple-Barrier	Probabilidades del LightGBM
Corrección de desequilibrio	compute_sample_weight	scale_pos_weight	Heredada del LightGBM
Calibración	Isotónica post-fit	No	No
Hiperparámetros	Optuna (TPE)	Optuna (TPE)	Profundidad fija / λ L1

Tabla 5. Comparativa de los tres modelos de la Iteración 1

3.3.5 Modelos entrenados en la Iteración 2

La Iteración 2 incorpora un HMM gaussiano para identificar el régimen de mercado en cada momento y condicionar las señales de la Iteración 1. Los parámetros se estiman mediante Baum-Welch y las probabilidades de estado mediante el algoritmo forward-backward, que produce probabilidades suavizadas $\gamma_t(k)$: la probabilidad de estar en el estado k en el instante t condicionada a toda la secuencia. Esto es preferible a una asignación binaria porque incorpora la incertidumbre sobre el régimen: un día con $\gamma_t(\text{bull})=0.35$ recibe un tratamiento distinto a uno con $\gamma_t(\text{bull})=0.80$ (Rabiner, 1989). El HMM se ajusta sobre las mismas ventanas walk-forward usando como observaciones el retorno logarítmico diario,

la volatilidad EWM-20 y el VIX, con cinco inicializaciones aleatorias para ganar robustez frente a óptimos locales.

La elección de $K=2$ estados surgió de un proceso iterativo: la configuración inicial con $K=3$ clasificaba más del 83% del OOS como no alcista, lo que hacía la estrategia inoperable. Con $K=2$ la partición es más nítida y un umbral $\gamma_t(\text{bull}) > 0.30$ produce una cobertura temporal representativa.




Figura 4. Regímenes HMM - Fold 6 (train 2004-2019)

3.4 Validación del rendimiento

3.4.1 Métricas de clasificación

La evaluación usa dos métricas complementarias. El F1-score es la métrica principal: con un 38% de clase positiva, la accuracy resulta engañosa porque premia a los modelos que predicen siempre la clase mayoritaria, mientras que el F1 penaliza ese comportamiento directamente. El AUC-ROC actúa como métrica secundaria, evaluando la calidad de las probabilidades estimadas con independencia del umbral; un $\text{AUC} > 0.5$ constante en todos los pliegues es la condición mínima de capacidad discriminativa real.

Ambas métricas se calculan por pliegue de forma independiente. Una desviación estándar alta entre pliegues indica sensibilidad al régimen de mercado, lo que motivó directamente el filtro HMM de la Iteración 2.

3.4.2 Ajuste del umbral de clasificación

El umbral estándar de 0.5 asume clases equilibradas y costes de error iguales, dos condiciones que no se cumplen con una prevalencia del 38% de clase positiva. Por eso el umbral se determina empíricamente para cada modelo y pliegue maximizando el F1-score en el rango [0.10, 0.70] sobre el conjunto de validación. El resultado es un umbral en torno a 0.30 para la mayoría de los pliegues, coherente con la prevalencia real, y se aplica sin ajustes en la evaluación fuera de muestra.

3.4.3 Estabilidad temporal de la importancia de variables

Se analiza la estabilidad de la importancia de las variables a lo largo de los seis pliegues mediante valores SHAP calculados en cada ventana de entrenamiento. Una variable relevante en todos los pliegues indica que el modelo está capturando un patrón estructural genuino; una con relevancia fluctuante sugiere ajuste al ruido de un periodo concreto.

Este análisis también sirve para comparar modelos: cuando el EBM y el LightGBM coinciden en las variables más relevantes, la probabilidad de que esa relevancia sea un artefacto de una arquitectura concreta se reduce considerablemente.

Variable	SHAP medio EBM	Folds EBM	SHAP medio LGBM	Folds LGBM
zscore_20	0.255	6/6	0.200	6/6
yield_curve	0.227	6/6	0.161	6/6
return_5d	0.189	6/6	0.172	6/6
drawdown	0.172	6/6	0.137	6/6
retail_sales_percent	0.150	6/6	0.136	6/6
vix	0.155	5/6	0.097	5/6
trend_strength	0.145	6/6	0.110	6/6
oil	0.136	6/6	0.127	6/6
sector_XLK	0.123	6/6	0.092	6/6
vol_regime	0.117	6/6	0.111	6/6

Tabla 6. Importancia SHAP media — Top 10 variables

3.4.4 Validación del HMM en la Iteración 2

Al no haber etiqueta de referencia, la calidad del HMM se evalúa con tres criterios. El primero es la separación estadística entre estados mediante el test de Mann-Whitney sobre los retornos medios de cada régimen. El segundo es la persistencia de los estados a través de la diagonal de la matriz de transición, ya que regímenes de corta duración no son accionables en la práctica. El tercero es la estabilidad del etiquetado entre pliegues, verificando que el estado alcista identificado en cada ventana corresponde al mismo tipo de régimen en las seis iteraciones.

Además, se evalúa el impacto del filtro sobre las métricas de clasificación supervisada: la señal condicionada, definida como la intersección entre la señal del clasificador y la

condición $y_i(\text{bull}) > 0.30$, se compara con la señal original en términos de precisión, recall y F1 por pliegue, para ver si la mejora en calidad de las señales activas compensa la reducción en su frecuencia.

3.5 Interpretación del modelo

3.5.1 Enfoque general de interpretabilidad

En finanzas, un modelo no auditable impide saber si está capturando patrones económicamente coherentes o simplemente ruido estadístico. La interpretabilidad no es un objetivo secundario, sino un criterio de diseño. El pipeline la aborda en tres niveles:

Nivel	Modelo	Mecanismo	Tipo de explicación
1 — Exacta	EBM	Shape functions	Contribución exacta y global de cada variable
2 — Post-hoc	LightGBM	SHAP (TreeExplainer)	Contribución marginal aproximada por predicción
3 — Por reglas	Student	RuleFit / árbol de decisión	Condiciones IF-THEN directamente legibles

Tabla 7. Niveles de interpretabilidad del pipeline

3.5.2 Shape functions del EBM

Para cada variable j el EBM aprende una función unidimensional exacta $f_j(x_j)$ que describe su contribución al log-odds de la predicción a lo largo de todo su rango de valores. A diferencia de los valores SHAP, que hacen aproximaciones locales por predicción, las shape functions son la representación exacta y global del modelo, sin ninguna brecha de aproximación. El análisis se realiza sobre el modelo del último pliegue, examinando la dirección del efecto y el rango activo de cada variable relevante. Las interacciones $f_{ij}(x_i, x_j)$ se visualizan como mapas de calor bidimensionales; su presencia con importancia significativa indica que la estructura predictiva no es puramente aditiva y justifica usar el EBM con interacciones en lugar de un GAM estándar.

3.5.3 Análisis de importancia SHAP sobre LightGBM

Para LightGBM se calculan valores SHAP con TreeExplainer, que aprovecha la estructura de árboles para obtener contribuciones de Shapley exactas y eficientes (Lundberg y Lee, 2017). La importancia global de cada variable se resume como la media del valor absoluto de sus SHAP sobre el conjunto de entrenamiento, lo que produce un ranking directamente comparable con el del EBM. La convergencia entre ambos rankings es uno de los análisis más relevantes del trabajo: cuando dos arquitecturas tan distintas identifican consistentemente las mismas variables como más relevantes, la evidencia de señal predictiva real es considerablemente más sólida.

3.5.4 Destilación y extracción de reglas del modelo student

El student se entrena para imitar las probabilidades del LightGBM, no las etiquetas originales. Cuando RuleFit converge, el resultado es un conjunto de condiciones IF-THEN ponderadas que pueden leerse como reglas de decisión financieramente interpretables. Cuando se usa el árbol de decisión como alternativa, la estructura jerárquica del árbol permite una lectura similar, aunque menos flexible.

En ambos casos, el objetivo es el mismo: traducir el comportamiento del LightGBM en reglas que puedan analizarse y cuestionarse sin necesidad de acceder al modelo original.

3.5.5 Convergencia metodológica entre modelos

El análisis de interpretabilidad incluye una comparación sistemática entre los tres modelos. Si el EBM, el LightGBM y el student identifican las mismas variables como determinantes y las reglas del student son coherentes con las shape functions del EBM, se obtiene evidencia de que el sistema captura patrones económicamente genuinos. La convergencia se analiza cuantitativamente mediante el solapamiento entre rankings de importancia y cualitativamente traduciendo reglas y formas funcionales al lenguaje financiero.

3.6 Generación de predicciones fuera de muestra

El periodo fuera de muestra, de enero de 2020 a diciembre de 2024, permanece bloqueado durante todo el desarrollo y se abre una única vez al finalizar el modelado. Los modelos usados son los entrenados en el último pliegue del walk-forward, cuyo conjunto de entrenamiento abarca 2004–2019. Esta elección tiene dos razones: es el modelo con más datos de entrenamiento y, por tanto, con estimaciones estadísticamente más estables, y reproduce fielmente las condiciones de información disponibles en la práctica en enero de 2020.

Para los tres modelos de la Iteración 1, el proceso es idéntico: se calculan las variables predictivas usando solo información disponible hasta el cierre del día anterior, se aplica el modelo para obtener la probabilidad de señal alcista, y se genera una señal binaria comparando esa probabilidad con el umbral optimizado durante la validación del último pliegue. No hay ningún ajuste posterior.

En la Iteración 2 se añade una etapa: el HMM del último pliegue se aplica al periodo fuera de muestra para calcular las probabilidades γ_t en cada día. La señal condicionada es la intersección entre la señal del clasificador y la condición $\gamma_t(\text{bull}) > 0.30$. La señal de breakout añade además la condición de que el precio de cierre esté por encima de su media móvil de veinte días.

Tanto el umbral $\gamma_t = 0.30$ como la ventana de la media móvil se determinaron durante el desarrollo sobre el periodo de entrenamiento, sin acceso a los datos del OOS. La sustitución de la señal de breakout con componente de volatilidad por la condición más simple de precio sobre media móvil respondió a que el componente de volatilidad eliminaba

señales en periodos que correspondían a mercados alcistas de alta volatilidad, un problema detectado sobre el periodo de validación.

3.7 Backtesting con señales diarias

3.7.1 Diseño de la estrategia de evaluación

El backtesting convierte las señales binarias en una estrategia de inversión concreta. La estrategia es long-only: cuando el modelo emite una señal positiva, se toma una posición larga en el S&P 500 al día siguiente hábil; cuando es negativa, la cartera queda en efectivo. No se implementan posiciones cortas para las señales negativas, lo que es coherente con el diseño del Triple-Barrier: la clase negativa agrupa tanto la activación del stop-loss como el agotamiento del horizonte sin tocar ninguna barrera, y no discrimina entre mercado bajista y mercado lateral.

El retorno diario de la estrategia es el producto entre la señal del día anterior y el retorno del índice en el día t , menos el coste de transacción si la posición ha cambiado. Usar la señal del día anterior garantiza que no se introduce sesgo de ejecución.

3.7.2 Modelización de costes de transacción

Los costes se modelizan con un spread de cinco puntos básicos por cambio de posición, representativo del coste de ejecución de los futuros E-mini S&P 500. Una señal ruidosa puede tener Sharpe bruto positivo pero negativo neto de costes, por lo que incluirlos no es un detalle cosmético sino una condición necesaria para evaluar la estrategia de forma realista.




Figura 5. Evolución de los diferenciales bid-ask de una acción típica del S&P 500 en los últimos 24 años.
Source: Bloomberg, Goldman Sachs Global Investment Research

3.7.3 Métricas de evaluación financiera

El rendimiento de cada estrategia se evalúa con cuatro métricas, calculadas también para el benchmark Buy and Hold como referencia.

Métrica	Definición	Dimensión evaluada
Sharpe ratio	Retorno medio / σ retornos diarios $\times \sqrt{252}$	Retorno ajustado al riesgo total
Máximo drawdown	Mayor caída acumulada desde máximo a mínimo	Peor escenario de pérdida sostenida
Calmar ratio	Sharpe / Máximo drawdown	Retorno ajustado al riesgo de caída
Barrier Score	Fracción de días invertidos con retorno positivo	Alineación señal-objetivo Triple-Barrier

Tabla 8. Métricas de evaluación financiera

El Barrier Score conecta directamente la señal del modelo con el objetivo del etiquetado: mide en qué proporción los días seleccionados son efectivamente días alcistas, más allá del rendimiento acumulado. Una estrategia con menor Sharpe que el Buy and Hold pero mayor Calmar y Barrier Score puede ser interesante para inversores con aversión al riesgo de caída.

3.8 Iteración 1 — Clasificación supervisada con modelos interpretables

3.8.1 Punto de partida y objetivos de la iteración

La Iteración 1 establece la línea base de modelos puramente supervisados sobre el target Triple-Barrier, sin información de régimen. El objetivo no es maximizar el rendimiento sino cuantificar qué señal predictiva es capturable en estas condiciones, de modo que la Iteración 2 pueda medir el valor incremental del filtro de régimen de forma limpia. Cualquier diferencia entre iteraciones es atribuible exclusivamente al componente añadido.

#	Hipótesis	Verificación
H1	El EBM con corrección de desequilibrio obtiene $F1 > 0$ en walk-forward	$F1$ medio > clasificador trivial
H2	La importancia SHAP de las variables principales es estable entre pliegues	Mapa de calor y frecuencia de aparición
H3	El student retiene la mayor parte del AUC del LightGBM con reglas acotadas	AUC student / AUC LGBM
H4	Al menos un modelo genera Sharpe positivo en OOS	Backtest 2020–2024

Tabla 9. Hipótesis de la Iteración 1

3.8.2 Decisiones metodológicas y aprendizajes durante el desarrollo

El desarrollo fue iterativo, con cinco ajustes que solo tienen sentido en el contexto de los problemas que resolvieron.

#	Problema identificado	Solución adoptada
---	-----------------------	-------------------

1	InterpretML ignora silenciosamente <code>class_weight</code> en el constructor del EBM, produciendo $F1 \approx 0$ en la clase positiva	Calcular pesos explícitamente con <code>compute_sample_weight</code> y pasarlos al método <code>.fit()</code>
2	El EBM generaba probabilidades brutas en un rango muy estrecho, haciendo el análisis de umbral no informativo	Calibración isotónica post-entrenamiento (<code>CalibratedClassifierCV</code>) para reescalar al intervalo unitario
3	Asimetría metodológica: LightGBM con Optuna vs EBM con hiperparámetros fijos, sesgando la comparación	Extender la búsqueda Optuna al EBM, garantizando condiciones equitativas
4	Configuración inicial de LightGBM (50 trials, hasta 1000 estimadores) inviable en tiempo de cómputo	Reducir a 30 trials y 500 estimadores máximo, verificando ausencia de pérdida significativa en validación
5	RuleFit no convergía de forma consistente en todos los pliegues independientemente de los ajustes de complejidad	Generalizar el student como categoría que agrupa RuleFit (si converge en tiempo límite) y árbol de decisión como alternativa, seleccionando por AUC en validación

Tabla 10. Decisiones metodológicas de la Iteración 1

3.8.3 Selección de variables por pliegue

La selección de variables se realiza de forma independiente dentro de cada pliegue, usando solo el conjunto de entrenamiento de ese pliegue. Si se eligieran las variables observando todo el dataset, las seleccionadas habrían sido escogidas parcialmente por su capacidad de ajustar el periodo de validación, inflando las métricas de forma artificial.

El proceso sigue dos fases. Primero se entrena un LightGBM auxiliar sobre el conjunto de entrenamiento del pliegue y se calculan los valores SHAP para obtener un ranking de importancia; se seleccionan las quince variables con mayor importancia SHAP media absoluta. Después se eliminan las redundantes entre las seleccionadas: cuando dos variables tienen una correlación de Pearson absoluta superior a 0.70, se descarta la de menor importancia SHAP. El LightGBM auxiliar no se usa para predicción; su único propósito es producir el ranking de importancia.

3.8.4 Aprendizajes metodológicos de la Iteración 1

La ejecución completa de la Iteración 1 produjo tres aprendizajes que condicionan directamente el diseño de la Iteración 2.

#	Aprendizaje	Implicación para la Iteración 2
1	La variabilidad del rendimiento entre pliegues es sustancial: las métricas difieren notablemente entre periodos de baja y alta volatilidad, sugiriendo que la señal depende del régimen de mercado vigente	Motivación empírica directa para incorporar detección de régimen
2	La convergencia entre EBM y LightGBM en el ranking de variables más importantes es alta, reduciendo la probabilidad de que la relevancia sea un artefacto del método de estimación	Refuerza la validez de la señal identificada y la selección de variables para la Iteración 2
3	La destilación produce resultados heterogéneos: RuleFit converge con AUC comparable al de LightGBM en algunos pliegues, pero en otros supera el tiempo límite y se recurre al árbol de decisión	La heterogeneidad no invalida el análisis de interpretabilidad, pero evidencia limitaciones de estabilidad computacional a considerar al interpretar el student

Tabla 11. Aprendizajes metodológicos de la Iteración 1

3.9 Iteración 2 — Detección de régimen y señal condicionada

3.9.1 Motivación y objetivos de la iteración

La Iteración 2 surge del primer aprendizaje de la Iteración 1: la variabilidad entre pliegues sugiere que la señal supervisada depende del régimen de mercado. La pregunta que guía esta iteración es si es posible identificar automáticamente en qué condiciones las señales son más fiables y activarlas solo en esos momentos. La respuesta propuesta es un HMM que actúe como filtro: los patrones que el clasificador asocia con señales alcistas pueden generar más falsos positivos en mercados bajistas o de alta incertidumbre.

#	Hipótesis	Verificación
H5	El HMM K=2 identifica dos estados con retornos estadísticamente distintos (bull: $\mu > 0$, bear: $\mu < 0$)	Test Mann-Whitney $p < 0.05$ sobre retornos por estado en OOS
H6	La señal condicionada $y_t(\text{bull}) > 0.30$ mejora el Sharpe	$\Delta \text{Sharpe iter1} \rightarrow \text{iter2} > 0$; umbral económico relevante: mejora superior al coste de implementación del filtro
H7	OOS para al menos un modelo respecto a la Iteración 1	MaxDD breakout < MaxDD iter2 en valor absoluto para al menos un modelo
H8	La señal de breakout (precio > MA20) reduce el MaxDD sin sacrificar el Sharpe obtenido en iter2	Mayoría de señales activas de iter2 producidas en días clasificados como régimen bull
	Las señales de iter2 se concentran en periodos con $y_t(\text{bull})$ alto, evidenciando que el filtro HMM es informativo y no aleatorio	

Tabla 12. Hipótesis de la Iteración 2

3.9.2 Decisiones metodológicas y aprendizajes durante el desarrollo

Las dos revisiones más relevantes afectaron al número de estados del HMM y al umbral de activación.

#	Decisión inicial	Problema identificado	Solución adoptada
1	K=3 estados HMM (bull / lateral / bear)	>83% del OOS clasificado como no alcista; el estado lateral absorbe periodos económicamente alcistas (2020-2021, 2023-2024), colapsando la actividad de la estrategia a niveles no evaluables	K=2 estados (bull / bear): partición más nítida, coherente con la tendencia alcista estructural del S&P 500 y cobertura OOS representativa
2	Umbral de activación $y_t(\text{bull}) > 0.50$	Señales excesivamente selectivas que reducen la cobertura temporal sin mejora proporcional de las métricas de rendimiento	Umbral $y_t(\text{bull}) > 0.30$, identificado como punto de equilibrio entre selectividad y cobertura sobre los pliegues de validación; fijo en OOS sin ajuste posterior

Tabla 13. Decisiones metodológicas de la Iteración 2

Ambas decisiones se tomaron sobre el periodo de validación, sin acceso a los datos del OOS.

3.9.3 Exploración de una capa adicional de confirmación de tendencia

Como extensión de la Iteración 2 se exploró añadir una señal de breakout basada en la posición del precio respecto a su media móvil de veinte días. La hipótesis era que la confirmación de tendencia de corto plazo podría filtrar las operaciones con peor rendimiento, concentrando la actividad en días donde tanto el régimen estructural como la dinámica técnica fueran favorables a la vez.

Los resultados sobre el periodo de validación no respaldaron esta hipótesis. La señal de breakout no mejoró las métricas de forma consistente y su principal efecto fue reducir el número de señales activas sin traducirse en mejor Sharpe ni menor drawdown. Se descartó su incorporación al sistema definitivo. Se documenta aquí por completitud metodológica: la confirmación técnica de corto plazo no añade valor cuando la señal ya está condicionada por un filtro de régimen estructural.

3.9.4 Aprendizajes metodológicos de la Iteración 2

El desarrollo de la Iteración 2 produjo tres aprendizajes con implicaciones directas para la interpretación de los resultados finales.

#	Aprendizaje	Implicación para el análisis de resultados
1	El HMM es muy sensible al número de estados y al umbral de activación: una configuración restrictiva puede producir métricas de clasificación aparentemente buenas (señales muy precisas) pero con actividad tan reducida que el sistema pierde utilidad práctica	Cualquier mejora de precisión debe evaluarse conjuntamente con la cobertura temporal; métricas de clasificación altas no son suficientes sin actividad representativa
2	La coherencia del HMM en el periodo de entrenamiento no garantiza su mantenimiento en el OOS: el periodo 2020-2024 incluye episodios sin precedente directo en el histórico (crash COVID-19, ciclo de subidas de tipos de 2022)	La capacidad de generalización del HMM es uno de los aspectos más relevantes a examinar en el análisis de resultados
3	La combinación de modelo supervisado y no supervisado introduce ambigüedad interpretativa: cuando la señal condicionada mejora respecto a la no condicionada, no es posible determinar automáticamente si la mejora proviene de la identificación correcta de regímenes o de la simple reducción de actividad en periodos de alta volatilidad	La comparación iter1 vs iter2 permite aislar el efecto del filtro HMM, pero la atribución causal de la mejora requiere análisis adicional en la sección de resultados

Tabla 14. Aprendizajes metodológicos de la Iteración 2

4. Resultados

4.1 Resultados de la Iteración 1

4.1.1 Rendimiento en validación walk-forward

La Tabla 15 recoge las métricas de clasificación medias de los tres modelos a lo largo de los seis pliegues del walk-forward, calculadas con el umbral optimizado individualmente para cada pliegue y modelo.

Modelo	F1 medio	Desv. típ. F1	AUC medio	Desv. típ. AUC	F1 mín.	F1 máx.
EBM	0.507	0.047	0.549	0.064	0.450	0.563
LightGBM	0.511	0.051	0.599	0.046	0.446	0.582
RuleFit/DT	0.477	0.138	0.598	0.054	0.208	0.573

Tabla 15. Resumen de métricas de validación walk-forward — Iteración 1

Los tres modelos obtienen F1 medio positivo y AUC superior a 0.5, lo que confirma la hipótesis H1: las variables construidas contienen información útil para la clasificación supervisada. La diferencia de F1 entre el EBM y el LightGBM es mínima (0.004 puntos), lo que indica que la mayor interpretabilidad del EBM tiene un coste de rendimiento casi nulo en validación. El LightGBM logra un AUC 0.05 puntos mayor, pero esta mejora en la ordenación de probabilidades no se traduce en diferencias apreciables en las predicciones finales una vez aplicado el umbral optimizado.

El modelo student muestra una variabilidad del F1 mucho más alta que los otros dos (0.138 frente a 0.047 y 0.051), con un mínimo de 0.208 en el pliegue 4. Esto es consistente con la heterogeneidad computacional descrita en la metodología: los pliegues donde RuleFit no converge bien producen árboles de decisión más sensibles a las condiciones concretas del periodo de validación.

La Tabla 16 presenta el F1 y el AUC por pliegue y modelo.

Pliegue	Periodo val.	F1 EBM	AUC EBM	F1 LGBM	AUC LGBM	F1 Student	AUC Student
1	2014	0.508	0.536	0.513	0.577	0.516	0.602
2	2015	0.481	0.640	0.446	0.679	0.455	0.629
3	2016	0.450	0.561	0.531	0.606	0.544	0.626
4	2017	0.561	0.594	0.459	0.613	0.208	0.517
5	2018	0.563	0.462	0.582	0.577	0.573	0.661
6	2019	0.476	0.498	0.536	0.543	0.564	0.554

Tabla 16. Métricas de validación por pliegue — Iteración 1

La variabilidad entre pliegues es alta en los tres modelos. Los mejores resultados aparecen en periodos de mayor volatilidad, como 2018, y los peores en mercados más estables y alcistas, como 2019. Esto sugiere que los modelos capturan mejor la señal en entornos de

incertidumbre, lo que refuerza la necesidad de incorporar un filtro de régimen en la Iteración 2.




Figura 6. Comparativa de modelos - métricas de validación por fold

4.1.2 Selección de variables y estabilidad SHAP

La Tabla 17 muestra las variables seleccionadas en cada pliegue. El conjunto es muy estable: un núcleo de diez variables aparece en todos o casi todos los pliegues en ambos modelos.

Variable	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Fold 6	Total folds
zscore_20	✓	✓	✓	✓	✓	✓	6/6
yield_curve	✓	✓	✓	✓	✓	✓	6/6
return_5d	✓	✓	✓	✓	✓	✓	6/6
drawdown	✓	✓	✓	✓	✓	✓	6/6
retail_sales_percent	✓	✓	✓	✓	✓	✓	6/6
trend_strength	✓	✓	✓	✓	✓	✓	6/6
sector_XLK	✓	✓	✓	✓	✓	✓	6/6
oil	✓	✓	✓	✓	✓	✓	6/6
vol_regime	✓	✓	✓	✓	✓	✓	6/6
vix	✓	✓	✓	✓	✓	✓	5/6
volatility_20	—	—	✓	✓	✓	—	3/6

Tabla 17. Variables seleccionadas por pliegue (EBM y LightGBM)

La Tabla 18 recoge la importancia SHAP media de las diez variables principales según EBM y LightGBM.

Variable	SHAP medio EBM	Folds EBM	SHAP medio LGBM	Folds LGBM
zscore_20	0.255	6/6	0.200	6/6
yield_curve	0.227	6/6	0.161	6/6
return_5d	0.189	6/6	0.172	6/6

drawdown	0.172	6/6	0.137	6/6
retail_sales_percent	0.150	6/6	0.136	6/6
vix	0.155	5/6	0.097	5/6
trend_strength	0.145	6/6	0.110	6/6
oil	0.136	6/6	0.127	6/6
sector_XLK	0.123	6/6	0.092	6/6
vol_regime	0.117	6/6	0.111	6/6

Tabla 18. Importancia SHAP media — Top 10 variables

El solapamiento entre los rankings del EBM y del LightGBM es completo: las diez variables más importantes son las mismas en ambos modelos, con diferencias únicamente en el orden relativo. Esta coincidencia entre dos arquitecturas muy distintas, con mecanismos de explicabilidad también distintos, es la evidencia más sólida de que las variables identificadas contienen señal predictiva genuina y no son un artefacto del método de estimación. Esto verifica la hipótesis H2.




Figura 7. Estabilidad SHAP entre folds – EBM




Figura 8. Estabilidad SHAP entre folds – LGBM

Desde el punto de vista financiero, las variables más importantes tienen una interpretación coherente. La puntuación z del precio respecto a su media de veinte días (zscore_20) encabeza el ranking en ambos modelos: la posición relativa del precio dentro de su rango reciente es la señal técnica con mayor capacidad discriminativa. La curva de tipos (yield_curve) ocupa la segunda posición, lo que refleja su papel histórico como predictor del ciclo económico. El retorno acumulado a cinco días (return_5d) captura el momentum de corto plazo, el drawdown mide el nivel de estrés estructural del mercado, y la presencia consistente del sector tecnológico (sector_XLK) refleja el liderazgo de este sector en la dinámica del S&P 500 durante el periodo analizado.

4.1.3 Análisis del modelo student

La Tabla 19 compara el rendimiento de RuleFit y del árbol de decisión en los seis pliegues del walk-forward, indicando el modelo seleccionado como student definitivo en cada caso.

Pliegue	F1 RuleFit	AUC RuleFit	F1 DT	AUC DT	Student seleccionado
1	0.516	0.602	0.514	0.562	RuleFit
2	0.455	0.629	0.405	0.572	RuleFit
3	0.544	0.626	0.524	0.636	DT
4	0.208	0.517	0.486	0.538	DT
5	0.573	0.661	0.584	0.551	RuleFit
6	0.564	0.554	0.544	0.573	DT

Tabla 19. Comparativa RuleFit vs Árbol de Decisión por pliegue

RuleFit converge en cuatro de los seis pliegues. En el pliegue 4, su AUC cae a 0.517 frente al 0.538 del árbol de decisión, que se selecciona como student. El AUC medio del student seleccionado (0.598) es el 99.8% del AUC medio del LightGBM (0.599), lo que verifica la

hipótesis H3: la destilación no supone una pérdida de información relevante.




Figura 9. Comparativa destilación - RuleFit vs Árbol de Decisión

Los árboles destilados tienen una profundidad de cinco niveles y entre quince y veinticuatro hojas según el pliegue. En cuatro de los seis pliegues la primera partición se realiza sobre `return_5d`, lo que indica que la dirección del retorno acumulado de la semana previa es la condición más discriminante a nivel global. La variable de segundo nivel varía entre pliegues, alternando entre `yield_curve`, `zscore_20` y `vol_regime`, lo que refleja que el contexto macroeconómico y técnico relevante cambia entre ventanas temporales aunque el conjunto de variables consideradas sea estable.

4.1.4 Resultados del backtest fuera de muestra

La Tabla 20 recoge las métricas financieras del backtest fuera de muestra (2020-2024) para los tres modelos y el benchmark Buy and Hold, netas de costes de transacción de cinco puntos básicos por cambio de posición

Modelo	F1 OOS	AUC OOS	Sharpe	Max. Drawdown	Calmar	Barrier Score	N señales
Buy & Hold	—	—	0.560	-0.361	1.552	—	—
EBM	0.174	0.485	0.339	-0.129	2.620	0.536	110
LightGBM	0.510	0.546	0.459	-0.353	1.300	0.539	763
Student	0.505	0.557	0.441	-0.337	1.307	0.534	664

Tabla 20. Métricas financieras del backtest OOS 2020-2024 — Iteración 1

Los tres modelos obtienen Sharpe positivo en el periodo fuera de muestra, verificando la hipótesis H4. Sin embargo, el perfil riesgo-retorno de cada uno es bastante distinto.

El EBM tiene el Sharpe más bajo (0.339) pero también el drawdown más reducido (-0.129 frente a -0.353 del LightGBM). Su Calmar de 2.620 supera al del Buy and Hold (1.552), lo que lo convierte en la opción más defensiva del conjunto. Este comportamiento viene directamente del número de señales activas: solo 110 en cinco años (unas 22 por año), lo que implica que la estrategia permanece en efectivo la mayor parte del tiempo. El Barrier Score de 0.536 confirma que la señal tiene capacidad discriminativa real aunque su

cobertura sea limitada: en el 53.6% de los días en que el EBM está invertido, el mercado cierra al alza.

El LightGBM y el Student tienen un perfil distinto: Sharpe más alto (0.459 y 0.441) pero con un drawdown cercano al del Buy and Hold (-0.353 y -0.337). Con 763 y 664 señales respectivamente, ambos modelos están invertidos casi todo el tiempo y quedan expuestos a los episodios bajistas del periodo, especialmente el crash de marzo de 2020 y el mercado bajista de 2022.

Año	Buy & Hold	EBM	LightGBM	Student
2020	0.433	0.296	-0.159	-0.006
2021	1.817	1.189	1.502	1.427
2022	-0.897	0.286	-0.131	-0.003
2023	1.672	0.000	2.002	0.718
2024	1.654	0.000	1.278	1.542

Tabla 21. Sharpe anual por modelo — OOS 2020-2024

El análisis anual muestra varios patrones relevantes. En 2022, año de caída sostenida (Sharpe del Buy and Hold de -0.897), el EBM es el único modelo con Sharpe positivo (0.286): su alta selectividad le permite evitar parcialmente el entorno bajista. LightGBM y Student también limitan las pérdidas respecto al Buy and Hold, pero no llegan a ser positivos.

En 2023 y 2024, el EBM no activa ninguna señal, lo que hace que su Sharpe sea 0.000 en ambos años. La estrategia no participa en el mercado alcista de esos dos ejercicios, lo que explica que su Sharpe acumulado sea inferior al de LightGBM y Student a pesar de tener mejor perfil de drawdown.




Figura 10. Equity Curves OOS (2020-2024) - threshold=0.3




Figura 11. Diagnóstico OOS - Performance anual desagregada

La Figura 10 muestra las curvas de equity acumuladas de los tres modelos frente al Buy and Hold a lo largo del periodo 2020-2024, y la Figura 11 presenta el mapa de calor del Sharpe anual, donde se visualiza con claridad la asimetría entre el comportamiento defensivo del EBM y la mayor exposición del LightGBM y el Student.

4.2 Resultados de la Iteración 2

4.2.1 Validación del modelo HMM: caracterización de regímenes

La Tabla 22 recoge las estadísticas de emisión de los dos estados identificados por el HMM en el último pliegue del walk-forward, que es el modelo aplicado al periodo fuera de muestra.

Estado	Frecuencia	Retorno anual	Volatilidad anual	Sharpe aprox.	Asimetría	N días
S0 — Bear	33.8%	-11.8%	24.7%	-0.416	-0.175	1.272
S1 — Bull	66.2%	+14.0%	10.3%	1.403	-0.227	2.493

Tabla 22. Estadísticas de emisión por estado HMM — Pliegue 6 (entrenamiento 2004-2019)

La separación entre estados es clara tanto estadísticamente como desde el punto de vista financiero. El estado bull concentra el 66.2% de los días de trading con un retorno anualizado del +14.0% y una volatilidad del 10.3%, produciendo un Sharpe de 1.40. El estado bear cubre el 33.8% restante con un retorno de -11.8% y una volatilidad más del doble (24.7%), lo que confirma la asimetría estructural entre ambos regímenes. Esto verifica la hipótesis H5.

Pliegue	Retorno anual bull	Frecuencia bull	Retorno anual bear	Frecuencia bear
1	+14.3%	66.9%	-13.9%	33.1%
2	+14.0%	69.0%	-13.5%	31.0%
3	+13.0%	69.9%	-13.9%	30.1%
4	+12.5%	69.6%	-11.4%	30.4%
5	+12.7%	70.3%	-9.4%	29.7%
6	+14.0%	66.2%	-11.8%	33.8%

Tabla 23. Estabilidad de los regímenes HMM entre pliegues

El etiquetado es estable entre pliegues. La frecuencia del estado bull oscila entre el 66.2% y el 70.3%, y su retorno anualizado se mantiene entre el +12.5% y el +14.3% en todos los pliegues. El estado bear presenta mayor variabilidad en su retorno (entre -9.4% y -13.9%), lo que es coherente con la naturaleza heterogénea de los episodios bajistas del periodo 2004–2019, que van desde correcciones moderadas hasta la crisis de 2008–2009. Esta consistencia indica que el HMM está capturando una propiedad estructural del mercado y no ajustándose al ruido de cada ventana temporal.




Figura 12. Régimen HMM en OOS (2020-2024)




Figura 13. Distribución por estado HMM - Fold 6

La Figura 4 y Figura 13 muestran respectivamente la evolución de los regímenes sobre el precio histórico del S&P 500 y la distribución de retornos y volatilidades por estado en el último pliegue, donde se aprecia visualmente la separación entre ambos regímenes.

4.2.2 Efecto del filtro HMM en la validación walk-forward

La Tabla 24 compara las métricas de clasificación medias en validación entre la señal original de la Iteración 1 y la señal condicionada por régimen de la Iteración 2.

Modelo	F1 iter1	F1 iter2	$\Delta F1$	Señales iter1	Señales iter2	Reducción
EBM	0.401	0.349	-0.052	91	71	-22%
LightGBM	0.521	0.487	-0.034	178	141	-21%
Student	0.518	0.476	-0.042	170	138	-19%

Tabla 24. Comparativa de métricas de validación walk-forward — Iter1 vs Iter2

El filtro produce un patrón consistente en los tres modelos: el F1 medio baja, pero la precisión sube. Esto es lo esperado: al eliminar señales en días de régimen adverso se pierden algunos verdaderos positivos (baja el recall), pero las señales que quedan son más selectivas (sube la precisión). La reducción media de señales activas es del 20–22%, es decir, el filtro elimina aproximadamente una de cada cinco señales del clasificador supervisado.

4.2.3 Resultados del backtest fuera de muestra

Versión	Modelo	Sharpe	Max. Drawdown	Calmar	Retorno total	Barrier Score	N señales
Buy & Hold	—	0.560	-0.361	1.552	62.2%	—	—
Iter1	EBM	0.339	-0.129	2.620	14.4%	0.536	110
Iter1	LightGBM	0.459	-0.353	1.300	41.4%	0.539	763
Iter1	Student	0.441	-0.337	1.307	36.2%	0.534	664
Iter2	EBM	0.614	-0.015	41.357	5.1%	0.625	24
Iter2	LightGBM	0.536	-0.084	6.373	17.7%	0.559	323
Iter2	Student	0.450	-0.093	4.815	13.8%	0.554	297
Breakout	EBM	0.330	-0.015	22.200	1.9%	0.714	14
Breakout	LightGBM	-0.122	-0.094	-1.303	-3.7%	0.556	216
Breakout	Student	-0.121	-0.101	-1.201	-3.4%	0.556	198

Tabla 25. Métricas financieras OOS — comparativa Iter1, Iter2 y Breakout

El filtro HMM aporta valor incremental sobre la Iteración 1 en los tres modelos, verificando la hipótesis H6. El patrón es consistente: los tres mejoran su Sharpe y reducen el drawdown al condicionar las señales al régimen alcista.

El caso más llamativo es el EBM condicionado: el Sharpe pasa de 0.339 a 0.614, superando por primera vez al Buy and Hold (0.560), mientras que el drawdown cae de -0.129 a -0.015. El Calmar resultante de 41.357 es muy alto, aunque hay que interpretarlo con cautela dado que el modelo solo activa 24 señales en cinco años, lo que hace que la muestra estadística sea pequeña. El Barrier Score sube a 0.625: en el 62.5% de los días en que el modelo está invertido, el mercado cierra al alza.

El LightGBM condicionado mejora el Sharpe de 0.459 a 0.536 y reduce el drawdown de -0.353 a -0.084, con un Calmar que pasa de 1.300 a 6.373. Con 323 señales activas, ofrece el mejor equilibrio entre cobertura temporal y mejora del perfil riesgo-retorno dentro de la Iteración 2. El Student condicionado mejora menos en Sharpe (de 0.441 a 0.450) pero reduce el drawdown de -0.337 a -0.093, con un Calmar que pasa de 1.307 a 4.815.

Los resultados del breakout confirman la decisión de descartarlo. Para LightGBM y Student, la capa adicional produce Sharpe negativos (-0.122 y -0.121 respectivamente). El EBM mantiene un Sharpe positivo en la versión breakout (0.330), pero es inferior al de la Iteración 2 (0.614) y prácticamente igual al de la Iteración 1 (0.339), lo que confirma que el breakout no añade valor una vez aplicado el filtro de régimen.

Año	Buy & Hold	EBM iter1	EBM iter2	LGBM iter1	LGBM iter2	Student iter1	Student iter2
2020	0.433	0.296	0.764	-0.159	-0.915	-0.006	-1.163
2021	1.817	1.189	1.783	1.502	1.372	1.427	1.352
2022	-0.897	0.286	-0.543	-0.131	-1.085	-0.003	-1.105
2023	1.672	0.000	0.000	2.002	1.009	0.718	0.696
2024	1.654	0.000	0.000	1.278	1.072	1.542	1.253

Tabla 26. Sharpe anual por modelo y versión — OOS 2020-2024

El análisis anual muestra cómo funciona el filtro HMM en la práctica. En 2020, el EBM condicionado mejora claramente (de 0.296 a 0.764): el HMM identifica correctamente los días alcistas del año del crash de COVID-19, evitando la caída de marzo y capturando parte de la recuperación posterior. Sin embargo, el LightGBM y el Student empeoran en ese mismo año bajo la Iteración 2 (de -0.159 a -0.915 y de -0.006 a -1.163 respectivamente): al reducir el número de señales activas, el filtro elimina precisamente las que estos modelos habrían ejecutado en los mejores días del año.

En 2022, el EBM de la Iteración 1 era el único modelo con Sharpe positivo (0.286), pero ese comportamiento desaparece en la Iteración 2 (-0.543). Esto indica que la selectividad del EBM en ese año respondía a su propio criterio de selección de señales, no al régimen HMM, que en 2022 clasifica como alcistas algunos periodos en los que el mercado finalmente cae.

En 2023 y 2024, el EBM no genera ninguna señal en ninguna de las dos versiones, lo que confirma que la ausencia de actividad en esos años es una característica del modelo y no un efecto del filtro. LightGBM y Student registran en esos años una ligera caída del Sharpe en la Iteración 2 respecto a la Iteración 1, lo que es consistente con la reducción de señales activas.




Figura 14. Equity Curves OOS 2020-2024




Figura 15. Sharpe anual OOS - Iter1 vs Iter2 vs Breakout

4.3 Análisis de explicabilidad e interpretabilidad

4.3.1 Convergencia metodológica entre EBM y LightGBM

El punto de partida del análisis de interpretabilidad es la convergencia entre los dos modelos principales. Como muestra la Tabla 18, las diez variables más importantes son idénticas en el EBM y en el LightGBM, con diferencias solo en el orden relativo. Esta coincidencia es relevante porque los mecanismos de explicabilidad son distintos en cada modelo: funciones de forma exactas en el EBM frente a valores SHAP post-hoc en el LightGBM. Que ambos lleguen al mismo resultado reduce considerablemente la probabilidad de que las variables identificadas sean un artefacto de una arquitectura concreta.

4.3.2 Shape functions del EBM

Las funciones de forma del EBM (Figura 16) permiten traducir el comportamiento del modelo al lenguaje financiero de forma exacta. Cada función describe la contribución de una variable a la predicción en log-odds a lo largo de todo su rango de valores observados, sin ninguna aproximación.




Figura 16. EBM - Shape functions (Fold 6, train hasta 2018-12-31)

Los patrones son no lineales, lo que justifica usar un modelo con esa capacidad en lugar de una regresión logística estándar. La función de forma de `zscore_20` muestra un efecto positivo y creciente en el rango de valores moderados que se invierte en niveles extremos de sobrecompra: el momentum técnico moderado es alcista, pero los niveles muy elevados resultan contraproducentes. La función de `yield_curve` presenta un efecto positivo en

valores bajos y moderados, coherente con la relación histórica entre pendiente de la curva y dinamismo bursátil, que se debilita cuando la curva alcanza valores muy altos.

La función del drawdown es marcadamente no lineal: drawdowns moderados tienen un efecto ligeramente positivo sobre la probabilidad de señal alcista, lo que puede interpretarse como la captura del efecto rebote desde correcciones normales del mercado, mientras que drawdowns severos tienen un efecto claramente negativo, coherente con la dificultad de recuperación en mercados bajistas profundos.




Figura 17. EBM - Importancia global y dirección del efecto (fold 6)

La estabilidad de la dirección del efecto entre pliegues es tan relevante como la estabilidad de la importancia: si una variable pasa de contribuir positivamente a negativamente entre periodos, la relación que el modelo ha aprendido es inestable y tiene menor capacidad de generalización fuera de muestra.

4.3.3 Reglas del modelo student

Los árboles destilados tienen cinco niveles de profundidad en todos los pliegues y entre quince y veinticuatro hojas. En cuatro de los seis pliegues el árbol comienza dividiendo el espacio por return_5d con un umbral en torno a cero, separando los días con retorno semanal negativo de los positivos. Esta partición inicial refleja que la dirección del momentum de corto plazo es la condición más discriminante a nivel global, lo que es coherente con su alta importancia SHAP en ambos modelos.

A partir de esa primera partición, las ramas incorporan condiciones sobre variables macroeconómicas y de volatilidad. La Tabla 27 resume las condiciones más frecuentes en las hojas positivas de los árboles destilados, es decir, las combinaciones de variables que el modelo asocia con señal alcista.

Condición	Interpretación financiera	Frecuencia entre pliegues
return_5d $\leq$ 0 AND drawdown $\leq$ umbral bajo	Corrección reciente con estrés estructural elevado	5/6 pliegues
return_5d $\leq$ 0 AND yield_curve $\leq$ umbral bajo	Caída semanal con curva de tipos plana o invertida	4/6 pliegues
return_5d $>$ 0 AND vol_regime $\leq$ 1.0 AND zscore_20 $\leq$ umbral	Momentum positivo en entorno de baja volatilidad sin sobrecompra	4/6 pliegues
return_5d $\leq$ 0 AND retail_sales_percent $\leq$ umbral bajo	Caída semanal con deterioro del consumo	3/6 pliegues

Tabla 27. Condiciones de mercado recurrentes en las hojas alcistas del árbol destilado

5. Conclusiones

Este capítulo organiza las conclusiones en torno a tres ejes: el etiquetado con Barrera Triple, los modelos interpretables y la detección de régimen. En cada uno se presentan primero los hallazgos que respaldan los resultados y después una reflexión crítica sobre lo que no funcionó o podría mejorarse. Al final se recogen las limitaciones, las líneas de trabajo futuro y la verificación de hipótesis.

5.1 Sobre el etiquetado con Barrera Triple

El Triple-Barrier mejora el enfoque directo de predecir la dirección del precio a n días porque incorpora dos elementos que ese enfoque ignora: el riesgo asumido durante la posición, a través del stop loss, y la gestión activa del horizonte temporal, a través de la barrera de tiempo. El objetivo de clasificación queda así más alineado con lo que realmente ocurre al operar en el mercado.

El dato que más respalda la solidez del diseño es la estacionariedad de la distribución de clases: un 38.3% de etiquetas positivas en entrenamiento frente a un 39.7% en el periodo fuera de muestra. En un OOS que incluye episodios tan distintos como el crash de marzo de 2020, el mercado alcista de 2021 y el bajista de 2022, que la prevalencia de la clase positiva se mantenga casi constante indica que el mecanismo de etiquetado no está sesgado hacia ningún régimen concreto y que los modelos afrontan condiciones comparables al generalizar al futuro.

Hay una matización relevante. El escalado de las barreras con la volatilidad hace que su amplitud dependa del régimen vigente. En años de alta volatilidad como 2018, las barreras son más amplias y las etiquetas reflejan movimientos más grandes, lo que facilita la discriminación. En mercados de baja volatilidad y tendencia unidireccional como 2019 o 2023, las barreras se estrechan y la señal es más difícil de capturar. Esto explica en parte por qué el rendimiento de los modelos varía según el entorno de mercado.

5.2 Sobre los modelos interpretables y el coste de la caja negra

5.2.1 Logros

El hallazgo más sólido en el ámbito de la interpretabilidad es la convergencia entre el EBM y el LightGBM: las diez variables con mayor importancia SHAP son idénticas en ambos modelos, con diferencias solo en el orden relativo. Que dos arquitecturas muy distintas, un modelo aditivo generalizado con interacciones de segundo orden y un ensemble de árboles con profundidad variable, lleguen de forma independiente al mismo ranking reduce considerablemente la probabilidad de que esa relevancia sea un artefacto de un método concreto. La señal identificada es robusta respecto al método de estimación.

Las variables que encabezan ese ranking son además económicamente coherentes. La puntuación z del precio respecto a su media de veinte días lidera en ambos modelos, lo que indica que la posición relativa del precio dentro de su rango reciente es la señal técnica con mayor capacidad discriminativa. La curva de tipos ocupa la segunda posición, en línea con su papel histórico como predictor del ciclo bursátil. El drawdown y el retorno acumulado a cinco días completan el núcleo del ranking, capturando el estrés estructural y el momentum de corto plazo respectivamente. Que la importancia estadística y la interpretación financiera apunten en la misma dirección es lo que distingue a un modelo que captura señal genuina de uno que ajusta ruido.

En cuanto al coste de la interpretabilidad, la diferencia en F1 medio en validación entre el EBM y el LightGBM es de 0.004 puntos. La interpretabilidad exacta del EBM resulta prácticamente gratuita en términos de rendimiento predictivo para este dataset y configuración.

La destilación también ha dado buenos resultados: el AUC medio del student seleccionado representa el 99.8% del AUC medio del LightGBM. Comprimir el conocimiento de un ensemble de cientos de árboles en un conjunto acotado de reglas IF-THEN o en un árbol de decisión de profundidad controlada no implica, en este caso, una pérdida de información sustancial.

5.2.2 Autocrítica

El proceso de destilación tiene una limitación de estabilidad computacional que conviene reconocer. RuleFit no converge de forma consistente en todos los pliegues: en dos de los seis se recurre al árbol de decisión como alternativa. En un entorno de producción, esta dependencia del tiempo de cómputo requeriría una solución más robusta que la alternancia entre ambos modelos.

La limitación más significativa del EBM aparece en 2023 y 2024: el modelo no genera ninguna señal en ninguno de los dos años, permaneciendo completamente en efectivo mientras el S&P 500 acumulaba retornos superiores al 20% en cada ejercicio. No es un fallo estadístico, porque el modelo simplemente no encuentra condiciones que superen su umbral de confianza. Pero sí revela un problema práctico real: una selectividad excesiva protege ante caídas pero puede dejar fuera mercados alcistas prolongados, lo que compromete la utilidad del sistema como generador de alfa a largo plazo.

5.3 Sobre el valor añadido de la detección de régimen

5.3.1 Logros

La separación entre los estados bull y bear del HMM es clara tanto estadísticamente como desde el punto de vista financiero: retorno anualizado de +14.0% con volatilidad del 10.3% en el estado bull frente a -11.8% con volatilidad del 24.7% en el estado bear. Que esta separación se mantenga estable a lo largo de los seis pliegues, con retornos del estado bull entre +12.5% y +14.3% según el pliegue, indica que el HMM está capturando una

propiedad estructural del mercado y no ajustándose al ruido de una ventana temporal concreta.

El impacto sobre las métricas financieras es consistente en los tres modelos. El LightGBM condicionado ilustra bien el patrón: el Sharpe pasa de 0.459 a 0.536 y el máximo drawdown se reduce de -0.353 a -0.084, con un Calmar que salta de 1.300 a 6.373. El filtro está haciendo lo que se esperaba: concentrar la actividad en los periodos estructuralmente favorables y reducir la exposición en los adversos.

5.3.2 Autocrítica y propuesta de mejora

Una limitación del diseño actual es que no siempre es posible determinar si la mejora de la Iteración 2 sobre la Iteración 1 viene de que el HMM identifica correctamente los regímenes o simplemente de que reduce la actividad en periodos de alta volatilidad, lo que mejora las métricas ajustadas al riesgo con independencia de la calidad del etiquetado. Esta ambigüedad se da porque el modelo supervisado se entrenó sobre todos los regímenes mezclados y el HMM actúa solo como filtro posterior.

Una mejora natural sería incorporar la variable de régimen HMM directamente como variable de entrada en el entrenamiento del clasificador supervisado, en lugar de usarla solo como filtro. El modelo aprendería así qué patrones son relevantes en cada régimen, entrenándose sobre la casuística en que realmente se pretende operar. Esta modificación podría introducir más riesgo de sobreajuste al reducir el espacio de entrenamiento, pero produciría señales más coherentes con el contexto de mercado en que se generan.

5.4 Sobre las señales financieras y su utilidad práctica

5.4.1 Logros

Los tres modelos obtienen Sharpe positivo en el periodo fuera de muestra 2020–2024, lo que confirma que la señal aprendida durante el entrenamiento generaliza al futuro. El Barrier Score se sitúa por encima de 0.53 en todos los modelos: más de la mitad de los días en que la estrategia está invertida el mercado cierra al alza, lo que indica que las señales seleccionan días favorables con una frecuencia superior al azar. En la Iteración 2, el EBM condicionado sube este valor hasta 0.625.

En términos de métricas ajustadas al riesgo, el LightGBM condicionado obtiene un Sharpe de 0.536 frente al 0.560 del Buy and Hold, pero con un máximo drawdown de -0.084 frente al -0.361 del benchmark. El Calmar de 6.373 más que cuadruplica el del Buy and Hold (1.552). Para un inversor con restricciones de riesgo o aversión al drawdown, ese intercambio es claramente favorable.

5.4.2 Reflexión sobre las equity curves

Hay una observación que los resultados muestran con claridad y que vale la pena tratar sin rodeos: todas las equity curves de los modelos quedan por debajo del Buy and Hold en

retorno acumulado. El Buy and Hold acumula un 62.2% entre 2020 y 2024; el mejor modelo en retorno absoluto, el LightGBM de la Iteración 1, acumula un 41.4%.

La razón es estructural. La estrategia long-only permanece en efectivo los días sin señal y, en los tres años más alcistas del periodo (2021, 2023 y 2024, con retornos del índice superiores al 20% en cada uno), los modelos filtran parte de esa exposición. El Buy and Hold la captura íntegramente. El valor del sistema no está en superar el retorno bruto del índice, objetivo que muy pocos gestores activos alcanzan de forma sostenida, sino en ofrecer un perfil de riesgo más controlado que puede ser útil para inversores con restricciones de drawdown o como componente dentro de una cartera más amplia.

5.5 Limitaciones del trabajo

Cinco limitaciones merecen señalarse explícitamente.

La primera es la restricción a un único activo. Todo el pipeline se ha desarrollado y evaluado sobre el S&P 500, por lo que no es posible saber si los patrones identificados son transferibles a otros mercados o clases de activos.

La segunda es la asimetría entre el mecanismo de etiquetado y el de evaluación. El Triple-Barrier define el objetivo en términos de una posición gestionada activamente con take profit y stop loss dinámicos, pero el backtest opera con holding diario. Los resultados no reflejan plenamente lo que el sistema podría hacer en un escenario de gestión activa de posiciones.

La tercera es la superficialidad del análisis del backtest. El rendimiento se ha evaluado a nivel global y anual, pero no se ha analizado casuísticas que podrían ser muy reveladoras: ¿las señales con mayor probabilidad asignada rinden mejor? ¿Las etiquetas que en entrenamiento tocaron el take profit generalizan mejor que las que agotaron el horizonte temporal? ¿Cómo se relaciona la persistencia de la señal con los costes de transacción? Un análisis más granular en estas dimensiones permitiría pasar de una evaluación descriptiva a un diagnóstico operativo real.

La cuarta es la dependencia de los parámetros de la Barrera Triple. Los valores $k=0.7$ y $h=7$ días hábiles se seleccionaron empíricamente sin un análisis de sensibilidad que cuantificara cuánto dependen los resultados de estas elecciones concretas.

La quinta es la heterogeneidad computacional del student. La inestabilidad de RuleFit en dos de los seis pliegues introduce una fuente de variabilidad en el análisis de interpretabilidad que en producción requeriría una solución más robusta.

5.6 Líneas de trabajo futuro

La limitación metodológicamente más relevante apunta también a la línea de desarrollo más prometedora: incorporar el régimen HMM como variable de entrada en el entrenamiento supervisado, en lugar de usarlo solo como filtro posterior. Esta modificación haría que el clasificador aprendiera directamente qué patrones son relevantes en cada

contexto de mercado, produciendo señales más adaptadas al régimen vigente y resolviendo la ambigüedad interpretativa actual.

Un backtest con barreras activas coherente con el Triple-Barrier es otra prioridad clara. Mantener cada posición abierta hasta tocar el take profit, el stop loss o agotar el horizonte de siete días produciría una evaluación más fiel al diseño del sistema y permitiría analizar la relación entre el nivel de confianza del modelo y el rendimiento por operación.

El análisis detallado de casuísticas específicas del backtest transformaría la evaluación actual de descriptiva a operativa: análisis por nivel de confianza de la señal, por tipo de barrera activada históricamente, por régimen de mercado y por persistencia de la señal.

Extender el pipeline a otros activos, como futuros sobre índices europeos, commodities o renta fija, permitiría evaluar si los patrones identificados son específicos del S&P 500 o reflejan propiedades más generales de los mercados financieros.

Por último, explorar variantes del modelo de régimen, incluyendo HMMs con $K=3$ y umbral dinámico adaptativo o el uso del meta-labeling como alternativa al filtro HMM (Singh y Joubert, 2019), podría mejorar la calidad del etiquetado de régimen y reducir la ambigüedad interpretativa entre identificación de régimen y reducción de exposición.

5.7 Verificación de hipótesis

#	Hipótesis	Resultado
H1	El EBM obtiene $F1 > 0$ en walk-forward	Verificada — $F1$ medio = 0.507
H2	Estabilidad SHAP de las variables principales entre pliegues	Verificada — Top-10 idéntico en EBM y LightGBM en todos los pliegues
H3	El student retiene la mayor parte del AUC del LightGBM	Verificada — $AUC_{student} = 99.8\%$ del AUC LightGBM
H4	Al menos un modelo genera Sharpe positivo en OOS	Verificada — Los tres modelos obtienen Sharpe > 0
H5	HMM $K=2$ identifica estados con retornos estadísticamente distintos	Verificada — Bull: +14.0% / Bear: -11.8% anual; estable entre pliegues
H6	La señal condicionada mejora el Sharpe OOS para al menos un modelo	Verificada — Los tres modelos mejoran Sharpe en iter2 respecto a iter1
H7	El breakout reduce el MaxDD sin sacrificar Sharpe	No verificada — Deteriora el Sharpe y reduce severamente las señales activas
H8	Las señales iter2 se concentran en periodos de $y_t(bull)$ alto	Verificada — Reducción del 20-22% de señales concentrada en días de régimen bear

Tabla 28 Resumen de verificación de hipótesis

Referencias

- Agarwal, R., Melnick, L., Frosst, N., Zhang, X., Lengerich, B., Caruana, R., & Hinton, G. (2020). Neural additive models: Interpretable machine learning with neural nets. *arXiv*. <https://arxiv.org/abs/2004.13912>
- Ang, A., & Timmermann, A. (2012). Regime changes and financial markets. *Annual Review of Financial Economics*, 4(1), 313–337. <https://doi.org/10.1146/annurev-financial-110311-101808>
- Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305. <https://jmlr.org/papers/v13/bergstra12a.html>
- Chevalier, G., Coqueret, G., & Raffinot, T. (2022). *Interpretable supervised portfolios*. SSRN. <https://doi.org/10.2139/ssrn.4230955>
- Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56. [https://doi.org/10.1016/0304-405X\(93\)90023-5](https://doi.org/10.1016/0304-405X(93)90023-5)
- Friedman, J. H., & Popescu, B. E. (2008). Predictive learning via rule ensembles. *The Annals of Applied Statistics*, 2(3), 916–954. <https://doi.org/10.1214/07-AOAS148>
- Fu, N., Kang, M., Hong, J., & Kim, S. (2024). Enhanced genetic-algorithm-driven triple barrier labeling method and machine learning approach for pair trading strategy in cryptocurrency markets. *Mathematics*, 12(5), 780. <https://doi.org/10.3390/math12050780>
- Grinold, R. C. (1989). The fundamental law of active management. *The Journal of Portfolio Management*, 15(3), 30–37.
- Gu, S., Kelly, B. T., & Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273. <https://doi.org/10.1093/rfs/hhz113>
- Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the knowledge in a neural network. *arXiv*. <https://arxiv.org/abs/1503.02531>
- Jansen, S. (2020). *Machine learning for algorithmic trading: Predictive models to extract signals from market and alternative data for systematic trading strategies* (2nd ed.). Packt Publishing.

- Jensen, M. C. (1968). The performance of mutual funds in the period 1945–1964. *The Journal of Finance*, 23(2), 389–416.
- Lal, G. R., Chen, X., & Mithal, V. (2024). TE2Rules: Explaining tree ensembles using rules. *arXiv preprint arXiv:2206.14359*. <https://arxiv.org/abs/2206.14359>
- López de Prado, M. (2018). *Advances in financial machine learning*. John Wiley & Sons.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, 30. https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html
- Microsoft. (2023). *LightGBM: A highly efficient gradient boosting decision tree framework* [Software]. GitHub. <https://github.com/microsoft/LightGBM>
- Molnar, C. (2022). *Interpretable machine learning: A guide for making black box models explainable* (3rd ed.). <https://christophm.github.io/interpretable-ml-book/>
- Nguyen, N. (2018). Hidden Markov model for stock trading. *International Journal of Financial Studies*, 6(2), 36. <https://doi.org/10.3390/ijfs6020036>
- Nori, H., Caruana, R., Bu, Z., Shen, J. H., & Kulkarni, J. (2021). Accuracy, interpretability, and differential privacy via explainable boosting. *arXiv*. <https://arxiv.org/abs/2106.09680>
- Oelschläger, L., & Adam, T. (2020). Detecting bearish and bullish markets in financial time series using hierarchical hidden Markov models. *arXiv*. <https://arxiv.org/abs/2007.14874>
- Sharpe, W. F. (1964). Capital asset prices: A theory of market equilibrium under conditions of risk. *The Journal of Finance*, 19(3), 425–442.
- Singh, A. K., & Joubert, J. (2019). Does meta-labeling add to signal efficacy? WorldQuant University. <https://hudsonthames.org/wp-content/uploads/2022/04/Does-Meta-Labeling-Add-to-Signal-Efficacy.pdf>
- Wang, M., Lin, Y.-H., & Mikhelson, I. (2020). Regime-switching factor investing with hidden Markov models. *Journal of Risk and Financial Management*, 13(12), 311. <https://doi.org/10.3390/jrfm13120311>

